

Vysoká škola ekonomická v Praze

Fakulta informatiky a statistiky



Analýza konvergence kriminality v EU metodami strojového učení

BAKALÁŘSKÁ PRÁCE

Studijní program: Aplikovaná informatika

Autor: Max Kubíček

Vedoucí bakalářské práce: prof. Ing. Petr Berka, CSc.

Praha, prosinec 2025

Čestné prohlášení

Čestně prohlašuji, že jsem bakalářskou práci na téma Digitalizace ve finanční správě, analýza a hodnocení ČR v EU kontextu vypracoval(a) samostatně. Veškeré použité informační zdroje jsem řádně citoval(a) a uvedl(a) v seznamu použité literatury.

Zároveň prohlašuji, že jsem při vypracování práce využil(a) generativní jazykový model ChatGPT společnosti OpenAI, a to v následujícím rozsahu:

- Zlepšení gramatiky a jazykového stylu: Nástroj byl použit k finální korektuře, stylistické úpravě autorského textu a k přepisu rozhovorů.
- Zpracování dat a analýza: AI byla využita jako pomocný nástroj při zpracování tematické analýzy.
- Generování zdrojových kódů: Model byl využit k vygenerování dílčích částí zdrojového kódu [zde můžete specifikovat, např. pro analýzu dat či vizualizaci].

Detailní popis rozsahu využití umělé inteligence, včetně specifikace upravovaných částí a popisu práce se zdrojovým kódem, uvádím v příloze práce v souladu s metodickými pokyny. Tento nástroj byl použit výhradně jako pomocný prostředek a za odborný obsah práce, interpretaci výsledků a veškeré závěry nesu plnou odpovědnost.

Poděkování

Rád bych poděkoval své rodině za podporu během celého studia, bez níž by jeho úspěšné dokončení nebylo možné.

Dále děkuji svým přátelům za psychickou podporu a pomoc v náročných obdobích studia. Zvláštní poděkování patří mému kamarádovi Michalovi Bukovčanovi za jeho pomoc a podporu při studiu.

V neposlední řadě bych chtěl poděkovat vedoucímu bakalářské práce prof. Ing. Petru Berkovi, CSc., za odborné vedení, cenné rady a ochotu pomoci po celou dobu zpracování této práce.

Zadání

Vysoká škola ekonomická v Praze
Katedra informačního a znalostního inženýrství

Fakulta informatiky a statistiky
Akademický rok: 2025/2026



ZADÁNÍ BAKALÁŘSKÉ PRÁCE

Zpracovatel: **Max Kubiček**

Studijní program: Aplikovaná informatika

Název tématu: **Analýza konvergence kriminality v EU metodami strojového učení**

Zásady pro vypracování:

1. Seznámit se s problematikou kriminality v jednotlivých zemích EU a s jejím vývojem po roce 2010.
2. Získat data mapující vývoj kriminality.
3. Navrhnout vhodnou úlohu strojového učení.
4. Vyřešit zvolenou úlohu.
5. Interpretovat výsledky analýzy.

Rozsah práce: 7 ECTS

Seznam odborné literatury:

1. GÉRON, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras and TensorFlow : concepts, tools, and techniques to build intelligent systems*. Beijing: O'Reilly, 2019. ISBN 978-1-4920-3264-9.
2. HAN, Jiawei; KAMBER, Micheline a PEI, Jian. *Data mining : concepts and techniques*. Amsterdam: Morgan Kaufmann is and imprint of Elsevier, 2012. ISBN 978-0-12-381479-1.
3. ŘEZANKOVÁ, Hana; HÚSEK, Dušan; SNÁŠEL, Václav. *Shluková analýza dat*. 2. vyd. Praha: PROFESSIONAL PUBLISHING, 2009. 218 s. ISBN 978-80-86946-81-8.
4. <https://ec.europa.eu/eurostat/data/database>
5. <https://www.unode.org/>

Datum zadání bakalářské práce: září 2025

Termín odevzdání bakalářské práce: květen 2026

Elektronicky schváleno dne 07. 10. 2025

Max Kubiček
Autor práce

Elektronicky schváleno dne 08. 10. 2025

prof. Ing. Petr Berka, CSc.
Vedoucí práce

Elektronicky schváleno dne 09. 10. 2025

doc. Ing. Vilém Sklenák, CSc.
Vedoucí katedry

Elektronicky schváleno dne 24. 10. 2025

doc. Ing. Ota Novotný, Ph.D.
Garant studijního programu

Abstrakt

Tato práce se zabývá vývojem kriminality v Evropské unii v období 2013–2023 se zaměřením na analýzu konvergence mezi členskými státy. Cílem práce je zhodnotit, zda dochází ke sblížování úrovně kriminality, a to s využitím kombinace tradičních statistických metod a metod strojového učení.

Analýza vychází z dat Eurostatu o kriminalitě a ekonomických ukazatelích, konkrétně HDP na obyvatele. Pro hodnocení vývoje variability kriminality v čase je využita sigma-konvergence, zatímco shluková analýza (K-means) slouží k identifikaci skupin států s podobným profilem kriminality. Zkoumány jsou vybrané typy trestné činnosti, včetně úmyslných vražd, loupeží, vloupání do obydlí a drogové kriminality.

Výsledky ukazují, že konvergence kriminality v Evropské unii není jednotná, ale liší se podle typu trestné činnosti. Zatímco u majetkové kriminality lze pozorovat trend sblížování mezi státy, drogová kriminalita zůstává výrazně heterogenní. U násilné kriminality je variabilita mezi státy nízká, což naznačuje, že k významné konvergenci došlo již v minulosti.

Shluková analýza odhalila existenci relativně stabilních skupin států, které odpovídají širším socioekonomickým a geografickým vzorcům, zejména rozdílu mezi západní a východní Evropou. Výsledky naznačují, že konvergence probíhá spíše uvnitř těchto skupin než napříč celou Evropskou unií.

Práce přispívá k pochopení vývoje kriminality v EU a ukazuje přínos kombinace statistických metod a metod strojového učení při analýze komplexních společenských jevů. Zároveň upozorňuje na význam institucionálních a socioekonomických faktorů při interpretaci mezinárodních srovnání kriminality.

Klíčová slova

Kriminalita, Evropská unie, konvergence, sigma-konvergence, shluková analýza, strojové učení, K-means, Eurostat, časové řady, socioekonomické faktory

Abstract

This thesis examines the development of crime in the European Union during the period 2013–2023, with a focus on the analysis of convergence among member states. The main objective is to assess whether crime levels are converging across countries using a combination of traditional statistical methods and machine learning techniques.

The analysis is based on Eurostat data on crime and economic indicators, specifically GDP per capita. Sigma convergence is applied to evaluate changes in the variability of crime over time, while cluster analysis (K-means) is used to identify groups of countries with similar crime profiles. The study focuses on selected types of criminal activity, including intentional homicide, robbery, burglary of private residential premises, and drug-related offences.

The results indicate that crime convergence in the European Union is not uniform and varies by type of offence. While property crime shows a tendency toward convergence, drug-related crime remains highly heterogeneous. In the case of violent crime, variability between countries is low, suggesting that significant convergence may have already occurred in earlier periods.

Cluster analysis reveals the existence of relatively stable groups of countries that correspond to broader socio-economic and geographical patterns, particularly the distinction between Western and Eastern Europe. The findings suggest that convergence occurs primarily within these groups rather than uniformly across the entire European Union.

This thesis contributes to a better understanding of crime dynamics in the EU and demonstrates the value of combining statistical methods with machine learning techniques in the analysis of complex social phenomena. It also highlights the importance of institutional and socio-economic factors in the interpretation of cross-country comparisons of crime.

Keywords

Crime, European Union, convergence, sigma convergence, cluster analysis, machine learning, K-means, Eurostat, time series, socio-economic factors

Obsah

Úvod.....	10
1 Teoretická východiska analýzy kriminality a konvergence.....	12
1.1 Kriminalita jako socioekonomický jev.....	12
1.2 Vývoj kriminality v Evropské unii po roce 2010	13
1.3 Pojem konvergence v ekonomii a sociálních vědách	14
1.3.1 Sigma-konvergence.....	15
1.3.2 Beta-konvergence	16
1.4 Dosavadní výzkumné studie konvergence kriminality	17
1.5 Limity tradičních statistických přístupů	18
2 Metody strojového učení v analýze kriminality	19
2.1 Strojové učení a jeho role v datové analýze	19
2.2 Metody bez učitele (unsupervised learning)	20
2.2.1 Shluková analýza (clustering).....	21
2.2.2 Měření podobnosti a vzdálenosti mezi státy	22
2.3 Analýza časových řad	23
2.4 Využití strojového učení v kriminologickém výzkumu.....	24
2.4.1 Prediktivní policing a analýza hotspotů.....	24
2.4.2 Hodnocení rizik a predikce recidivy	24
2.4.3 Detekce anomálií a finanční kriminalita	25
2.4.4 Strukturální srovnání a konvergenční studie.....	25
2.4.5 Metodologické a etické limity.....	25
3 Data a metodika zpracování.....	26
3.1 Použité datové zdroje	26
3.2 Konstrukce datové sady.....	27
3.3 Čištění a předzpracování dat	28
3.3.1 Ošetření chybějících hodnot	28
3.3.2 Normalizace a transformace proměnných	29
3.4 Explorační analýza dat (EDA)	30
3.5 Návrh výzkumných otázek a hypotéz.....	32
3.5.1 Výzkumné otázky.....	32
3.5.2 Hypotézy	32
3.6 Implementace analytického postupu.....	33
3.6.1 Načtení a příprava dat.....	34

3.6.2	Kontrola kvality dat	34
3.6.3	Výběr kategorií kriminality	34
3.6.4	Analýza sigma-konvergence	34
3.6.5	Regresní analýza beta-konvergence.....	34
3.6.6	Shluková analýza a PCA.....	35
3.6.7	Vizualizace výstupů	35
3.6.8	Reprodukovatelnost a modularita řešení.....	35
4	Empirická analýza konvergence kriminality v EU z vlastního výzkumu	36
4.1	Vývoj kriminality v zemích EU v čase	36
4.1.1	Celkový vývoj napříč kategoriemi	37
4.1.2	Vloupání do soukromých obydlí.....	37
4.1.3	Loupeže	38
4.1.4	Úmyslné vraždy	39
4.1.5	Drogová kriminalita	40
4.1.6	Shrnutí výsledků.....	41
4.2	Výsledky shlukové analýzy	41
4.2.1	Charakteristika jednotlivých shluků	43
4.2.2	Vztah ke konvergenci kriminality	44
4.2.3	Stabilita shluků v čase.....	45
4.3	Analýza trendů kriminality.....	45
4.4	Vyhodnocení míry konvergence mezi státy.....	47
5	Diskuse výsledků	49
5.1	Hlavní zjištění a sektorové rozdíly.....	49
5.2	Metodologické a teoretické závěry	49
5.3	Omezení a přínos práce	50
	Závěr	51
	Použitá literatura:	52
	Přílohy.....	54
	Příloha A: Dodatečné grafy a tabulky	54
	Příloha B: Ukázky kódu	54
	B.1 Skript pro přípravu dat	54
	B.2 Skript pro čištění a transformaci dat.....	55
	B.3 Výpočet sigma-konvergence	55
	B.4 Odhad beta-konvergence	56
	B.5 Shluková analýza států EU	56

B.6 Vizualizace výsledků	56
--------------------------------	----

Úvod

Bezpečnost a vývoj kriminality patří mezi významné ukazatele kvality života obyvatelstva, stability veřejných institucí a celkové společenské soudržnosti. Míra kriminality zároveň odráží širší ekonomické, sociální a institucionální podmínky jednotlivých zemí. Vysoká kriminalita bývá spojována se zvýšenými ekonomickými náklady, nižší důvěrou obyvatel ve veřejné instituce a negativními dopady na sociální rozvoj společnosti (Messner & Rosenfeld, 2001).

V podmínkách Evropské unie nabývá problematika kriminality zvláštního významu. Evropská integrace přinesla postupné prohlubování ekonomické spolupráce, rostoucí mobilitu osob, kapitálu i služeb a částečné sbližování životních podmínek mezi členskými státy. Tyto procesy mohou vytvářet předpoklady také pro konvergenci kriminality, tedy pro postupné snižování rozdílů v úrovni kriminality mezi jednotlivými zeměmi. Současně však v Evropské unii nadále přetrvávají rozdíly v ekonomické úrovni, kvalitě institucí, právních systémech, sociální struktuře i metodách evidence trestné činnosti, které mohou proces konvergence zpomalovat nebo omezovat (Eurostat, 2024; UNODC, 2015).

Kriminalita je komplexní společenský jev, jehož příčiny nelze vysvětlit jediným faktorem. Ekonomické přístupy zdůrazňují racionální rozhodování jednotlivců, kteří porovnávají očekávané výnosy a náklady trestné činnosti, včetně pravděpodobnosti odhalení a trestu (Becker, 1968). Na tento přístup navázaly další studie zdůrazňující význam příjmových příležitostí, nezaměstnanosti nebo sociálních nerovností (Ehrlich, 1973; Freeman, 1999). Sociologické teorie naopak upozorňují na význam sociální dezorganizace, anomie, oslabení společenských vazeb nebo institucionálních tlaků vyplývajících ze struktury společnosti (Merton, 1938; Messner & Rosenfeld, 2001). Vývoj kriminality je tedy výsledkem působení celé řady vzájemně propojených faktorů.

V posledních letech se zároveň výrazně rozšiřují možnosti empirického výzkumu kriminality díky dostupnosti rozsáhlých mezinárodních datových souborů a rozvoji moderních analytických nástrojů. Vedle tradičních statistických metod lze využít také metody strojového učení, které umožňují identifikovat skryté vzorce v datech, klasifikovat objekty do homogenních skupin nebo analyzovat vícerozměrné vztahy mezi proměnnými. Tyto přístupy se v současnosti uplatňují v řadě oblastí společenských věd a představují vhodný doplněk klasických kvantitativních metod (James et al., 2021; Hastie et al., 2009).

Předložená bakalářská práce reaguje na potřebu propojit společensky významné téma bezpečnosti s moderními metodami datové analýzy. Zaměřuje se na vývoj kriminality v členských státech Evropské unie v období 2013–2023 a usiluje o zhodnocení, zda mezi jednotlivými státy dochází ke konvergenci kriminality. Vedle tradičních ukazatelů konvergence jsou využity také metody strojového učení, zejména shluková analýza, která umožňuje identifikovat skupiny států s podobným profilem kriminality.

Cíl práce

Hlavním cílem této bakalářské práce je analyzovat vývoj kriminality v členských státech Evropské unie v období 2013–2023 a posoudit, zda mezi jednotlivými zeměmi dochází ke konvergenci kriminality.

Za účelem naplnění hlavního cíle byly stanoveny následující dílčí cíle:

- sestavení a očištění datového souboru z veřejně dostupných zdrojů,
- provedení explorační analýzy dat,
- vyhodnocení sigma-konvergence kriminality,
- testování beta-konvergence pomocí regresního modelu,
- aplikace shlukové analýzy za účelem identifikace skupin států s podobným profilem kriminality,
- interpretace výsledků v širším ekonomickém, institucionálním a bezpečnostním kontextu.

Metodika práce

Práce využívá kombinaci tradičních statistických metod a vybraných metod strojového učení. Pro hodnocení konvergence je použita analýza sigma-konvergence, sledující vývoj variability kriminality mezi státy v čase, a analýza beta-konvergence, testující vztah mezi počáteční úrovní kriminality a jejím následným vývojem. Dále je využita shluková analýza K-means pro identifikaci skupin států s podobnými charakteristikami. Pro grafickou interpretaci vícerozměrných vztahů je použita metoda hlavních komponent (PCA) (James et al., 2021).

Datový a analytický proces byl realizován v programovacím jazyce Python s využitím knihoven pandas, scikit-learn, statsmodels a matplotlib.

Struktura práce

Práce je rozdělena do několika navazujících kapitol. Druhá kapitola představuje teoretická východiska kriminality, konvergence a využití metod strojového učení v kriminologickém výzkumu. Třetí kapitola popisuje použítá data a metodologický postup. Čtvrtá kapitola obsahuje empirickou analýzu a prezentaci dosažených výsledků. Pátá kapitola je věnována diskusi výsledků, jejich interpretaci a možným implikacím pro bezpečnostní politiky Evropské unie. Závěr shrnuje hlavní zjištění práce a navrhuje možné směry dalšího výzkumu.

1 Teoretická východiska analýzy kriminality a konvergence

Cílem této kapitoly je vymezit teoretický rámec, ze kterého vychází následná empirická analýza konvergence kriminality v Evropské unii. Nejprve je kriminalita představena jako komplexní socioekonomický jev ovlivňovaný ekonomickými, institucionálními, demografickými a sociálními faktory. Následně je stručně popsán vývoj kriminality v Evropské unii po roce 2010, který vytváří základní kontext pro další analýzu (Eurostat, 2024).

Další část kapitoly se zaměřuje na koncept konvergence, jenž je tradičně využíván především v ekonomii při zkoumání sblížování regionů nebo států z hlediska hospodářské výkonnosti, avšak jeho aplikace je možná i v oblasti kriminality a dalších sociálních ukazatelů. Pozornost je věnována zejména vymezení sigma-konvergence a beta-konvergence jako dvou základních analytických přístupů (Barro & Sala-i-Martin, 2004).

Závěrečná část kapitoly diskutuje limity tradičních statistických metod při analýze komplexních vícerozměrných dat a zdůvodňuje využití metod strojového učení, které umožňují identifikovat skryté struktury, podobnosti a vzorce v rozsáhlých datových souborech. Tyto přístupy se v posledních letech stávají významným doplňkem klasických kvantitativních metod ve společenských vědách (Hastie et al., 2009; James et al., 2021).

1.1 Kriminalita jako socioekonomický jev

Kriminalitu lze chápat z různých perspektiv, nejčastěji však jako komplexní společenský jev vznikající působením ekonomických, sociálních, institucionálních a demografických faktorů. Nejde pouze o souhrn individuálních trestných činů, ale o širší fenomén, který odráží stav společnosti, kvalitu institucí a úroveň sociální soudržnosti. Z tohoto důvodu je kriminalita vhodným předmětem kvantitativní analýzy v čase i v mezinárodním srovnání.

Úroveň kriminality bývá ovlivněna ekonomickými podmínkami, zejména úrovní příjmů, nezaměstnaností, životní úrovní obyvatelstva a dostupností legálních ekonomických příležitostí. Významným teoretickým přístupem je ekonomická teorie kriminality Garyho S. Beckera, podle níž se jednotlivec rozhoduje o spáchání trestného činu na základě porovnání očekávaných výnosů a nákladů, včetně rizika odhalení a výše trestu (Becker, 1968). Na Beckerův přístup navázaly další studie, které zdůrazňují význam trhu práce, mzdových příležitostí a sociálního postavení jednotlivce (Ehrlich, 1973; Freeman, 1999).

Z ekonomického hlediska lze předpokládat, že kriminalita roste zejména tam, kde jsou omezené legální možnosti obživy, vysoká nezaměstnanost nebo nízké mzdy. Hrubý

domácí produkt na obyvatele bývá často využíván jako přibližný ukazatel celkové ekonomické prosperity a životní úrovně. Země s vyšší ekonomickou výkonností zpravidla disponují lepší sociální ochranou, vyšší úrovní vzdělání a kvalitnějšími institucemi, což může přispívat ke snižování některých forem kriminality. Současně však mohou vykazovat vyšší evidovanou kriminalitu v důsledku vyšší míry hlášení trestných činů a efektivnější evidence (Eurostat, 2024).

Vedle ekonomických faktorů hrají významnou roli také sociální nerovnosti. Empirický výzkum dlouhodobě poukazuje na pozitivní vztah mezi příjmovou nerovností a úrovní násilné kriminality. Ve společnostech s výraznými příjmovými rozdíly může docházet k oslabování sociální koheze, poklesu důvěry v instituce a růstu frustrace znevýhodněných skupin obyvatelstva, což může vést ke zvýšenému výskytu násilného chování (Fajnzylber et al., 2002; Wilkinson & Pickett, 2009). Na rozdíl od majetkové kriminality, která bývá citlivější na krátkodobé ekonomické výkyvy, je násilná kriminalita často spojena s dlouhodobými strukturálními nerovnostmi.

Významným faktorem jsou rovněž regionální rozdíly a prostorová koncentrace sociální deprivace. Oblasti charakterizované vysokou nezaměstnaností, nižší úrovní vzdělání a omezenou dostupností veřejných služeb vykazují tendenci k dlouhodobě vyšší kriminalitě. Tyto strukturální problémy se mohou reprodukovat v čase a přetrvávat i během období hospodářského růstu (Messner & Rosenfeld, 2001). V rámci Evropské unie se proto kriminalita nevyvíjí rovnoměrně, ale odráží rozdílnou míru sociální integrace jednotlivých států a regionů.

Rozdíly v kriminalitě mohou být ovlivněny také způsobem jejího měření a evidence. Statistiky kriminality neodrážejí pouze skutečné chování jednotlivců, ale jsou ovlivněny i institucionálním a právním rámcem dané země. Jedním z klíčových faktorů je ochota obyvatel hlásit trestné činy, která úzce souvisí s důvěrou ve stát, policii a justici. Dalším faktorem je efektivita policejních složek a jejich schopnost trestnou činnost odhalovat a statisticky zaznamenávat. Přestože Eurostat usiluje o harmonizaci dat mezi členskými státy, nelze plně odstranit rozdíly vyplývající z národních právních systémů (Eurostat, 2024).

Kriminalita je dále spojena s demografickou a prostorovou strukturou společnosti. Empirické studie často upozorňují na vliv věkové struktury obyvatelstva, kdy vyšší podíl mladých mužů bývá spojován s vyšší mírou kriminality. Významná je rovněž míra urbanizace, která souvisí s koncentrací obyvatelstva a anonymitou prostředí. Vztah mezi kriminalitou a migrací je komplexní a závisí na integračních politikách a socioekonomických podmínkách jednotlivých zemí (Eurostat, 2024; UNODC, 2015).

1.2 Vývoj kriminality v Evropské unii po roce 2010

Samotný vývoj kriminality v členských státech Evropské unie je charakteristický výraznou heterogenitou jak mezi jednotlivými zeměmi, tak mezi kategoriemi trestné činnosti. Zatímco některé státy zaznamenaly po roce 2010 výrazný a dlouhodobý pokles kriminality, jiné vykazovaly stagnaci nebo růst u vybraných druhů trestných činů. Tento rozdílný vývoj lze spojovat s kombinací ekonomických, demografických a institucionálních

faktorů, včetně doznívání finanční krize, změn ve věkové struktuře obyvatelstva nebo rozdílů v efektivitě trestněprávních systémů **(Eurostat, 2024)**.

Po roce 2010 lze v evropském prostoru sledovat také proměnu struktury kriminality. V mnoha státech dochází k poklesu tradiční majetkové kriminality, zejména krádeží a vloupání. Tento trend bývá spojován s rozšířením bezpečnostních technologií, vyšší ochranou majetku, digitalizací společnosti a změnou životního stylu obyvatelstva **(Eurostat, 2024)**. Naopak některé formy násilné kriminality vykazují spíše stabilní vývoj a u specifických kategorií lze v určitých obdobích pozorovat i růstové tendence.

Vedle tradičních forem kriminality zároveň narůstá význam nových typů trestné činnosti, zejména kyberkriminality, online podvodů nebo trestné činnosti spojené s digitálním prostředím. Tyto formy kriminality často překračují hranice jednotlivých států a jejich zachycení v oficiálních statistikách bývá metodologicky náročnější **(UNODC, 2015)**. Z tohoto důvodu nemusí být plně srovnatelné s tradičními kategoriemi trestné činnosti.

Vývoj kriminality po roce 2010 byl ovlivněn také širšími společenskými změnami. Patří mezi ně urbanizace, stárnutí populace, migrační pohyby, technologický rozvoj či proměna spotřebního chování domácností **(Eurostat, 2024)**. Některé z těchto faktorů mohou kriminalitu snižovat, jiné ji mohou transformovat do nových podob. Vývoj kriminality proto nelze chápat jako krátkodobý výkyv, ale spíše jako dlouhodobý proces odrážející hlubší strukturální změny ve společnosti.

Z hlediska této práce je podstatné, že rozdíly mezi členskými státy Evropské unie nespočívají pouze v absolutní úrovni kriminality, ale také v její vnitřní struktuře. Jednotlivé země se mohou lišit zastoupením majetkové, násilné, drogové nebo jiné kriminality, stejně jako tempem změn v čase. Právě dlouhodobý vývoj a strukturální proměny vytvářejí vhodný základ pro analýzu konvergence, tedy pro zkoumání, zda se úroveň a struktura kriminality mezi státy postupně sbližují, nebo zda mezi nimi přetrvávají či se prohlubují rozdíly.

1.3 Pojem konvergence v ekonomii a sociálních vědách

Pojem konvergence je v ekonomii a sociálních vědách používán k popisu procesu, při němž se rozdíly mezi jednotkami analýzy – nejčastěji státy, regiony nebo skupinami obyvatel – v čase zmenšují. Konvergence tak vyjadřuje tendenci k postupnému sbližování úrovně určitého sledovaného jevu, ať už se jedná o ekonomickou výkonnost, sociální ukazatele nebo další charakteristiky společnosti.

V ekonomii je koncept konvergence tradičně spojen s teoriemi hospodářského růstu. Zkoumá se zejména otázka, zda ekonomicky méně rozvinuté země dosahují v dlouhém období vyššího tempa růstu než země bohatší, čímž dochází ke snižování rozdílů v příjmech a životní úrovni. Tento přístup je úzce spojen především s neoklasickými růstovými modely a empirickými studiemi zaměřenými na dlouhodobé sbližování ekonomik **(Barro & Sala-i-Martin, 2004)**.

Postupně byl koncept konvergence rozšířen i do dalších oblastí společenského výzkumu, například do sociologie, politologie, regionálních studií nebo kriminologie

(Messner & Rosenfeld, 2001). V těchto oblastech bývá aplikován na jevy, jako jsou vzdělanost, zdravotní stav populace, příjmová nerovnost, kvalita institucí nebo kriminalita. Smyslem analýzy je zhodnotit, zda se mezi jednotlivými státy či regiony snižují rozdíly v úrovni sledovaného ukazatele, nebo zda naopak přetrvávají či se dále prohlubují.

V sociálních vědách je konvergence často chápána širěji než v čistě ekonomickém pojetí. Nejde pouze o sblížování absolutních hodnot sledovaného indikátoru, ale také o přibližování jeho struktury, dynamiky a vzorců chování mezi jednotlivými jednotkami. V případě kriminality tak konvergence nemusí znamenat pouze snižování rozdílů v celkové úrovni kriminality mezi státy, ale rovněž sblížování struktury trestné činnosti nebo podobný vývoj jednotlivých kategorií kriminality v čase.

Z hlediska empirické analýzy je pojem konvergence úzce spojen s kvantitativními metodami, které umožňují testovat, zda rozdíly mezi sledovanými jednotkami skutečně klesají. Tyto přístupy tvoří základ pro formální vymezení sigma-konvergence a beta-konvergence, které jsou podrobněji rozpracovány v následujících podkapitolách **(Barro & Sala-i-Martin, 2004).**

1.3.1 Sigma-konvergence

Sigma-konvergence představuje jeden ze základních konceptů používaných při empirickém zkoumání konvergence. Označuje situaci, kdy v čase dochází ke snižování variability sledovaného ukazatele mezi jednotlivými jednotkami analýzy, typicky státy nebo regiony. Jinými slovy, sigma-konvergence nastává tehdy, pokud se rozdíly v úrovni daného jevu mezi sledovanými jednotkami postupně zmenšují **(Barro & Sala-i-Martin, 2004).**

V ekonomickém výzkumu bývá sigma-konvergence nejčastěji měřena prostřednictvím statistických ukazatelů variability, jako jsou směrodatná odchylka, variační koeficient nebo rozptyl logaritmovaných hodnot sledované proměnné **(Barro & Sala-i-Martin, 2004).** Pokles těchto ukazatelů v čase je interpretován jako důkaz sblížování mezi jednotkami, zatímco jejich stagnace nebo růst signalizuje absenci konvergence, případně divergenci.

Výhodou sigma-konvergence je její relativní jednoduchost a přehlednost, neboť umožňuje rychle vyhodnotit, zda se mezi sledovanými jednotkami snižují rozdíly v určitém ukazateli. Tento přístup je proto často využíván při mezinárodních a regionálních komparacích, kde je cílem zachytit celkový trend vývoje nerovností mezi státy nebo regiony.

V kontextu analýzy kriminality sigma-konvergence umožňuje posoudit, zda se rozdíly v úrovni kriminality mezi členskými státy Evropské unie v čase zmenšují. Pokud například dochází ke snižování variability kriminality mezi státy, lze hovořit o sblížování bezpečnostní situace v evropském prostoru. Naopak růst variability by naznačoval prohlubování rozdílů mezi jednotlivými zeměmi.

Sigma-konvergence však nezohledňuje individuální dynamiku jednotlivých států ani mechanismy, které ke sblížování vedou **(Barro & Sala-i-Martin, 2004).** Neodpovídá například na otázku, zda státy s vyšší počáteční úrovní kriminality vykazují rychlejší pokles než státy s nižší kriminalitou. Poskytuje tedy spíše agregovaný a popisný pohled na vývoj

rozdílů mezi státy. Z tohoto důvodu je vhodné výsledky doplnit analýzou beta-konvergence, která se zaměřuje na dynamiku vývoje jednotlivých států.

1.3.2 Beta-konvergence

Beta-konvergence představuje dynamický přístup ke studiu konvergence, který se zaměřuje na vztah mezi počáteční úrovní sledovaného jevu a jeho následným vývojem v čase. Základní myšlenkou beta-konvergence je, že jednotky s vyšší počáteční úrovní sledovaného ukazatele by měly v následujícím období vykazovat pomalejší růst, případně rychlejší pokles, než jednotky s nižší počáteční úrovní. Pokud je tento vztah empiricky potvrzen, lze hovořit o přítomnosti beta-konvergence (**Barro & Sala-i-Martin, 2004**).

V ekonomii je beta-konvergence tradičně testována pomocí regresních modelů, v nichž je tempo růstu nebo změny sledované proměnné vysvětlováno její počáteční úrovní. Záporný a statisticky významný koeficient u počáteční hodnoty bývá interpretován jako důkaz konvergence, zatímco kladný koeficient naznačuje divergenci (**Barro & Sala-i-Martin, 2004**). Tento přístup umožňuje zachytit rozdílnou dynamiku vývoje jednotlivých jednotek, což představuje důležitý rozdíl oproti popisnému pojetí sigma-konvergence.

Výhodou beta-konvergence je skutečnost, že se nezaměřuje pouze na celkový vývoj variability, ale analyzuje samotný mechanismus sbližování. Umožňuje tedy zkoumat, zda jednotky s horší výchozí pozicí skutečně dohánějí jednotky s výchozí pozicí lepší, nebo zda mezi nimi rozdíly přetrvávají.

V empirickém výzkumu se obvykle rozlišuje mezi **absolutní a podmíněnou beta-konvergencí**. Absolutní beta-konvergence předpokládá, že všechny jednotky směřují ke stejnému dlouhodobému rovnovážnému stavu bez ohledu na své strukturální charakteristiky (**Barro & Sala-i-Martin, 2004**). Tento předpoklad je však v reálných společenských podmínkách často příliš zjednodušující. Podmíněná beta-konvergence proto připouští, že jednotlivé státy nebo regiony se liší svými ekonomickými, institucionálními či demografickými podmínkami, a do modelu zahrnuje další vysvětlující proměnné.

V oblasti kriminality lze beta-konvergenci využít k ověření, zda státy s vyšší počáteční úrovní kriminality vykazují rychlejší pokles kriminality než státy s nižší výchozí úrovní. Pokud by byl takový vztah potvrzen, naznačovalo by to postupné sbližování bezpečnostní situace mezi státy. Naopak neexistence statisticky významného vztahu by ukazovala, že samotná výchozí úroveň kriminality není dostatečným vysvětlením jejího dalšího vývoje.

Tento přístup je zvláště vhodný při práci s panelovými daty, která umožňují sledovat vývoj kriminality v jednotlivých státech v čase a současně kontrolovat vliv dalších faktorů. Beta-konvergence tak poskytuje hlubší vhled do dynamiky sbližování kriminality mezi státy Evropské unie než samotná analýza sigma-konvergence a představuje důležitý doplněk celkového empirického hodnocení konvergenčních procesů (**Barro & Sala-i-Martin, 2004**).

1.4 Dosavadní výzkumné studie konvergence kriminality

Empirický výzkum zaměřený na konvergenci kriminality je ve srovnání s rozsáhlou literaturou zabývající se ekonomickou konvergencí relativně omezený. Zatímco problematika sblížování ekonomické výkonnosti, příjmů nebo regionálních rozdílů patří mezi tradiční témata ekonomického výzkumu, oblast kriminality byla z tohoto pohledu zkoumána podstatně méně často (**Barro & Sala-i-Martin, 2004**). Přesto lze identifikovat řadu studií, které analyzují, zda a do jaké míry dochází ke sblížování úrovně či struktury kriminality mezi státy nebo regiony v delším časovém horizontu.

Dosavadní empirické práce se zpravidla opírají o analýzu sigma-konvergence a beta-konvergence s využitím tradičních ekonometrických metod (**Barro & Sala-i-Martin, 2004**). Výsledky těchto studií však nejsou jednoznačné. Některé výzkumy nacházejí důkazy o postupném sblížování vybraných typů kriminality, zejména u násilné kriminality nebo vražd, zatímco jiné poukazují na přetrvávající nebo dokonce rostoucí rozdíly mezi regiony a státy. Rozdílné závěry bývají často spojovány s odlišnou volbou datového souboru, časového období, geografického vymezení nebo použité metodologie.

Významným faktorem ovlivňujícím výsledky empirických analýz je rovněž způsob měření kriminality a její institucionální kontext. Řada studií upozorňuje na omezenou srovnatelnost dat, která vyplývá z rozdílných právních definic trestných činů, odlišné míry hlášení kriminality obyvatelstvem nebo rozdílů v efektivitě policejních složek a systému evidence. Pozorovaná konvergence nebo divergence tak může v některých případech odrážet spíše změny ve statistickém zachycení kriminality než skutečný vývoj kriminality jako společenského jevu (**Eurostat, 2024; UNODC, 2015**).

V odborné literatuře se zároveň opakovaně potvrzuje význam ekonomických a sociálních determinant kriminality. Výzkumy ukazují souvislost mezi kriminalitou a faktory, jako jsou nezaměstnanost, ekonomická nerovnost, sociální vyloučení nebo institucionální kvalita (**Becker, 1968; Fajnzylber et al., 2002; Freeman, 1999**). To naznačuje, že případná konvergence kriminality může být úzce spojena s širší konvergencí ekonomických a sociálních podmínek mezi jednotlivými zeměmi.

V posledních letech se objevují také studie usilující o překonání omezení tradičních přístupů prostřednictvím vícerozměrných metod a pokročilejších analytických nástrojů. Tyto práce se nezaměřují pouze na absolutní úroveň kriminality, ale také na její strukturu, prostorové souvislosti nebo podobnost mezi jednotlivými jednotkami. Rostoucí pozornost je věnována rovněž metodám strojového učení, které umožňují pracovat s rozsáhlými datovými soubory a identifikovat skryté vzorce v datech (**James et al., 2021**). V oblasti analýzy konvergence kriminality však jejich využití zůstává zatím spíše omezené.

Z tohoto důvodu lze dosavadní literaturu chápat jako důležité teoretické a metodologické východisko, které však ponechává prostor pro další výzkum. Zejména chybí systematické studie zaměřené na dlouhodobý vývoj struktury kriminality mezi státy Evropské unie s využitím kombinace konvergenčních testů a metod strojového učení. Předložená práce se snaží na tento výzkumný prostor navázat a přispět k hlubšímu pochopení vývoje kriminality v evropském kontextu.

1.5 Limity tradičních statistických přístupů

Tradiční statistické a ekonometrické přístupy hrají v analýze kriminality i konvergence významnou roli a poskytují základní nástroje pro popis dat, testování hypotéz a identifikaci vztahů mezi proměnnými. Mezi nejčastěji využívané metody patří korelační analýza, regresní modely, analýza časových řad nebo klasické konvergenční testy. Tyto přístupy však vykazují řadu omezení, zejména při analýze komplexních a vícerozměrných společenských jevů, jakým kriminalita bezpochyby je (**Hastie et al., 2009**).

Jedním z hlavních omezení tradičních metod je jejich časté zaměření na jednotlivé ukazatele analyzované odděleně. Takový přístup může opomíjet vzájemné vazby mezi různými kategoriemi trestné činnosti a neumožňuje zachytit kriminalitu jako propojený systém více souvisejících jevů. V kontextu konvergenční analýzy to může vést k neúplnému pohledu na vývoj rozdílů mezi státy, protože jednotlivé typy kriminality se mohou vyvíjet odlišně a současně vzájemně souviset.

Dalším problémem je omezená schopnost tradičních statistických metod pracovat s vyšším počtem proměnných. Analýza kriminality často zahrnuje více kategorií trestné činnosti i doplňkové socioekonomické ukazatele, jako jsou HDP na obyvatele, nezaměstnanost či demografická struktura. Při použití klasických regresních modelů se v takových případech může zvyšovat riziko multikolinearity, nestability parametrů a obtížnější interpretace výsledků (**James et al., 2021**).

Tradiční ekonometrické přístupy zároveň často předpokládají lineární vztahy mezi proměnnými a relativní stabilitu těchto vztahů v čase. V případě kriminality však nemusí být tyto předpoklady naplněny, neboť vývoj bývá ovlivňován nelineárními procesy, strukturálními změnami či legislativními zásahy (**Hastie et al., 2009**). Významným omezením může být také obtížná identifikace skrytých struktur v datech, jelikož klasické modely jsou primárně zaměřeny na testování předem formulovaných hypotéz.

Z uvedených důvodů se v posledních letech stále častěji uplatňují metody strojového učení, které mohou tradiční přístupy vhodně doplnit. Tyto metody umožňují pracovat s vícerozměrnými daty, analyzovat složitější vztahy a identifikovat skryté struktury bez nutnosti silných předpokladů o tvaru těchto vztahů (**Hastie et al., 2009; James et al., 2021**).

V rámci společenských věd se využívají zejména metody učení bez učitele, například shluková analýza, která umožňuje rozdělit státy do skupin podle podobnosti jejich charakteristik. Dalším užitečným nástrojem je analýza hlavních komponent (PCA), která umožňuje redukovat počet proměnných a přehledně vizualizovat vícerozměrná data (**James et al., 2021**). Metody strojového učení proto nepředstavují náhradu tradičních statistických postupů, ale jejich rozšíření, které umožňuje komplexnější pohled na problematiku kriminality v Evropské unii.

2 Metody strojového učení v analýze kriminality

Tato kapitola se zaměřuje na metody strojového učení a jejich využití při analýze kriminality, se zvláštním důrazem na aplikace vhodné pro konvergenční analýzu. V návaznosti na omezení tradičních statistických přístupů jsou metody strojového učení představeny jako nástroje umožňující pracovat s vícerozměrnými daty, zachytit složitější struktury a identifikovat vzorce podobnosti mezi sledovanými jednotkami bez nutnosti silných předpokladů o tvaru vztahů mezi proměnnými (**Hastie et al., 2009; James et al., 2021**).

Kapitola nejprve obecně vymezuje pojem strojového učení a jeho roli v moderní datové analýze. Pozornost je zaměřena zejména na **metody učení bez učitele**, které jsou vhodné pro explorační analýzu dat a porovnávání států podle struktury kriminality. Dále jsou představeny vybrané techniky, jako je shluková analýza, měření podobnosti mezi jednotkami a základní přístupy k analýze časových řad (**James et al., 2021**).

Samostatná část kapitoly je věnována dosavadním aplikacím metod strojového učení v kriminologickém výzkumu. Tyto přístupy se v posledních letech využívají například pro predikci kriminality, identifikaci rizikových lokalit (tzv. hotspotů), analýzu prostorových vzorců trestné činnosti nebo segmentaci územních celků podle bezpečnostních charakteristik (**Berk, 2017; Mohler et al., 2015**).

Cílem této kapitoly není detailní matematický popis jednotlivých algoritmů, ale jejich konceptuální vymezení a zdůvodnění vhodnosti pro analýzu konvergence kriminality v Evropské unii. Popsané metody následně tvoří metodologický základ empirické části této práce.

2.1 Strojové učení a jeho role v datové analýze

Strojové učení představuje oblast datové analýzy a umělé inteligence, která se zaměřuje na vývoj algoritmů schopných automaticky identifikovat vzorce, vztahy a struktury v datech bez nutnosti explicitního naprogramování všech pravidel mezi proměnnými. Na rozdíl od tradičních statistických metod, které často vycházejí z předem definovaných modelových předpokladů, umožňuje strojové učení flexibilnější přístup k analýze komplexních a vícerozměrných dat (**James et al., 2021**).

V širším kontextu lze strojové učení chápat jako soubor metod, které doplňují klasické statistické přístupy a rozšiřují možnosti explorační i prediktivní analýzy. Jeho využití je zvláště přínosné v situacích, kdy je obtížné předem specifikovat přesný tvar vztahů mezi proměnnými, kdy data obsahují větší množství vzájemně propojených ukazatelů nebo kdy se vyskytují nelineární závislosti mezi sledovanými jevy (**Hastie et al., 2009**).

Metody strojového učení se obvykle dělí na dvě základní skupiny: učení s učitelem a učení bez učitele. **Učení s učitelem** je založeno na existenci známé cílové proměnné, kterou se algoritmus snaží predikovat na základě vstupních dat. Tento přístup se využívá zejména v klasifikačních a regresních úlohách, například při odhadu rizika recidivy nebo predikci kriminality v určité lokalitě (**Berk, 2017; James et al., 2021**).

Učení bez učitele se naopak zaměřuje na odhalování skrytých struktur v datech bez existence explicitní cílové proměnné. Cílem není předpověď konkrétní hodnoty, ale identifikace podobností, segmentace pozorování nebo redukce dimenzionality dat (**Hastie et al., 2009; James et al., 2021**). Tyto metody jsou vhodné zejména pro explorační analýzu a srovnávání států, regionů či jiných jednotek podle jejich charakteristik.

V oblasti kriminality hrají metody strojového učení významnou roli zejména při práci s rozsáhlými datovými soubory zahrnujícími více kategorií trestné činnosti a doplňkové socioekonomické ukazatele. Umožňují identifikovat podobnosti a rozdíly mezi státy, sledovat změny ve struktuře kriminality v čase a odhalovat vzorce, které by při použití tradičních statistických metod mohly zůstat skryté (**Berk, 2017**).

Pro účely této práce mají zvláštní význam především metody učení bez učitele, jelikož cílem není predikce konkrétní hodnoty kriminality, ale analýza podobnosti mezi členskými státy Evropské unie a identifikace skupin zemí s obdobným profilem kriminality. Strojové učení tak představuje vhodný nástroj pro komplexní analýzu kriminality v mezinárodním srovnání a vhodně doplňuje klasické konvergenční přístupy.

2.2 Metody bez učitele (unsupervised learning)

Metody bez učitele (unsupervised learning) představují skupinu technik strojového učení, jejichž cílem je odhalování skrytých struktur, vzorců a vztahů v datech bez existence explicitně definované cílové proměnné. Na rozdíl od metod učení s učitelem zde algoritmus nepracuje s předem známým výsledkem, ale snaží se sám identifikovat přirozené uspořádání dat na základě podobnosti jednotlivých pozorování (**James et al., 2021**).

Tyto metody jsou využívány především v explorační fázi datové analýzy, kdy je cílem lépe porozumět vnitřní struktuře dat, rozpoznat skupiny podobných jednotek nebo zjednodušit složitou datovou strukturu (**Hastie et al., 2009; James et al., 2021**). V praxi se uplatňují zejména tehdy, pokud výzkumník nemá předem jasně definovanou hypotézu o rozdělení dat nebo pokud analyzovaný jev vykazuje vysokou míru komplexity.

V kontextu analýzy kriminality jsou metody bez učitele obzvláště vhodné, neboť kriminalita představuje vícerozměrný jev zahrnující různé kategorie trestné činnosti, jejichž vzájemné vztahy nemusí být předem známy. Unsupervised learning umožňuje analyzovat kriminalitu jako celek a pracovat s její strukturou, nikoli pouze s jednotlivými izolovanými ukazateli (**Berk, 2017**).

Typickým příkladem metod bez učitele jsou techniky **shlukové analýzy (clustering)**, které umožňují seskupovat státy, regiony nebo jiné jednotky do skupin na základě podobnosti jejich charakteristik (**James et al., 2021**). V případě této práce mohou

tyto metody odhalit skupiny států Evropské unie s podobným profilem kriminality a následně posoudit, zda se tato struktura v čase mění.

Další významnou oblast představují **metody redukce dimenzionality**, jejichž cílem je převést větší počet proměnných do menšího počtu nových souhrnných ukazatelů při zachování co největší části původní informace. Nejčastěji využívaným přístupem je analýza hlavních komponent (PCA), která umožňuje přehlednější vizualizaci složitých vícerozměrných dat (**Hastie et al., 2009**).

Výhodou metod bez učitele je jejich relativně nízká náročnost na předpoklady o tvaru vztahů mezi proměnnými. Umožňují tedy zachytit i složitější a nelineární struktury, které by tradiční statistické modely mohly přehlédnout. Současně však vyžadují obezřetnou interpretaci výsledků, protože identifikované struktury nejsou výsledkem testování explicitních hypotéz, ale spíše nástrojem pro deskriptivní a explorační analýzu (**James et al., 2021**).

V této práci jsou metody bez učitele využívány jako doplněk tradičních konvergenčních přístupů. Jejich hlavním přínosem je identifikace podobností mezi členskými státy Evropské unie a analýza vývoje struktury kriminality v čase, což umožňuje hlubší porozumění procesu konvergence kriminality nad rámec samotných statistických ukazatelů variability.

2.2.1 Shluková analýza (clustering)

Shluková analýza představuje jednu ze základních metod učení bez učitele, jejímž cílem je seskupovat jednotky analýzy do homogenních skupin na základě jejich vzájemné podobnosti. Jednotky zařazené do stejného shluku si jsou z hlediska sledovaných charakteristik více podobné než jednotky náležející do jiných skupin. Výsledkem shlukové analýzy je tedy rozdělení dat do skupin, které odrážejí vnitřní strukturu analyzovaného souboru (**James et al., 2021**).

V oblasti společenských věd je shluková analýza využívána zejména při zkoumání heterogenních souborů dat, kde předem neexistuje jednoznačné rozdělení pozorovaných jednotek. Umožňuje identifikovat latentní typologie států či regionů a následně interpretovat jejich společné znaky (**James et al., 2021**). V analýze kriminality lze tuto metodu využít ke klasifikaci států podle struktury a úrovně kriminality, případně podle kombinace kriminalitních a socioekonomických ukazatelů (**Berk, 2017**). Shluková analýza tak poskytuje doplňující vícerozměrný pohled ke konvergenční analýze založené na agregovaných ukazatelích variability.

Mezi nejčastěji používané metody patří hierarchické shlukování a algoritmus k-means. **Hierarchické shlukování** vytváří stromovou strukturu vztahů mezi jednotkami (dendrogram), která umožňuje analyzovat podobnost dat na různých úrovních agregace (**Hastie et al., 2009**). Výhodou této metody je přehlednost a možnost následného rozhodnutí o počtu výsledných shluků.

Algoritmus k-means patří mezi nejrozšířenější nehierarchické metody. Jeho princip spočívá v rozdělení dat do předem stanoveného počtu skupin tak, aby byla

minimalizována vnitroshluková variabilita a současně maximalizována odlišnost mezi jednotlivými shluky. Metoda je výpočetně efektivní a dobře použitelná i při větším množství dat, což vysvětluje její časté využití v aplikovaném výzkumu (**Hastie et al., 2009; James et al., 2021**).

Při aplikaci shlukové analýzy je nezbytné věnovat pozornost **předzpracování dat**, zejména standardizaci proměnných. Pokud by proměnné měly rozdílná měřítka, mohly by některé ukazatele nepřiměřeně ovlivnit výsledné rozdělení, což je kritické zejména u algoritmů založených na eukleidovské vzdálenosti (**James et al., 2021**). Důležitou otázkou je rovněž určení optimálního počtu shluků. V praxi se často využívá metoda lokte (elbow method), silhouette score nebo jiné validační postupy, které pomáhají nalézt kompromis mezi jednoduchostí modelu a schopností zachytit strukturu dat (**Hastie et al., 2009; James et al., 2021**).

V této práci je shluková analýza využita jako nástroj pro identifikaci podobností mezi členskými státy Evropské unie a pro analýzu vývoje struktury kriminality v období 2013–2023. Jejím hlavním přínosem je možnost zachytit širší vzorce podobnosti mezi státy, které by při použití pouze tradičních statistických metod nemusely být zřejmé.

2.2.2 Měření podobnosti a vzdálenosti mezi státy

Měření podobnosti a vzdálenosti mezi státy představuje klíčový krok při aplikaci shlukové analýzy i dalších vícerozměrných metod. Cílem je kvantifikovat, do jaké míry se jednotlivé státy liší nebo si naopak odpovídají z hlediska sledovaných charakteristik, v této práci zejména podle struktury a úrovně kriminality. Každý stát lze v analytickém pojetí chápat jako bod ve vícerozměrném prostoru, jehož souřadnice tvoří hodnoty jednotlivých proměnných (**James et al., 2021**). Vzdálenost mezi dvěma body pak vyjadřuje míru jejich podobnosti – čím je vzdálenost nižší, tím jsou si státy podobnější.

Podobnost mezi státy je zpravidla vyjadřována prostřednictvím vzdálenostních metrik, které shrnují rozdíly mezi vektory hodnot jednotlivých proměnných. Mezi nejčastěji používané patří eukleidovská vzdálenost, manhattanská vzdálenost a vzdálenost založená na korelaci (**James et al., 2021**).

Eukleidovská vzdálenost představuje nejběžnější metriku a odpovídá přímé geometrické vzdálenosti mezi dvěma body v prostoru. Je vhodná zejména tehdy, pokud mají proměnné podobný význam a jsou správně standardizovány. **Manhattanská vzdálenost** naproti tomu sčítá absolutní rozdíly mezi jednotlivými proměnnými a bývá méně citlivá na extrémní hodnoty (outliery) v datech (**Hastie et al., 2009; James et al., 2021**).

Korelační vzdálenost se soustředí spíše na podobnost struktury než na absolutní úroveň hodnot. Dva státy tak mohou být vyhodnoceny jako podobné, pokud vykazují obdobné proporce mezi jednotlivými druhy kriminality, i když se jejich celkové úrovně kriminality liší (**James et al., 2021**). Tento přístup je zvláště přínosný při zkoumání strukturálních vzorců kriminality v rámci konvergenční analýzy.

V analýze kriminality je měření vzdálenosti významně ovlivněno heterogenitou kategorií trestné činnosti. Některé ukazatele mohou dosahovat výrazně vyšších hodnot než

jiné, což by bez úpravy dat vedlo k jejich nepřiměřené dominanci při výpočtu vzdáleností. Z tohoto důvodu je před samotnou analýzou nezbytné provést **standardizaci nebo normalizaci dat**. Standardizace převádí proměnné na srovnatelné měřítko, zpravidla se střední hodnotou nula a směrodatnou odchylkou jedna. Tím je zajištěno, že jednotlivé proměnné vstupují do výpočtu podobnosti vyváženě (**Hastie et al., 2009**).

Měření podobnosti a vzdálenosti umožňuje nejen aplikaci shlukové analýzy, ale také sledování vývoje vztahů mezi státy v čase. Pokud se vzdálenosti mezi státy postupně snižují, může to indikovat proces sbližování jejich kriminalitních profilů. Z metodologického hlediska tak představuje měření podobnosti důležitý doplněk klasických konvergenčních testů, neboť umožňuje zachytit změny ve struktuře kriminality a širší vztahy mezi státy Evropské unie.

2.3 Analýza časových řad

Analýza časových řad představuje důležitý nástroj pro zkoumání vývoje sledovaných jevů v čase. Umožňuje identifikovat dlouhodobé trendy, cyklické pohyby, krátkodobé výkyvy i případné strukturální zlomy v datech. V oblasti společenských věd je tento přístup významný zejména tehdy, pokud je cílem porozumět dynamice určitého jevu, a nikoliv pouze jeho jednorázové úrovni (**James et al., 2021**).

V kontextu kriminality je časová dimenze zásadní, neboť vývoj odráží nejen krátkodobé změny, ale především dlouhodobé socioekonomické, demografické a institucionální procesy. Změny v míře kriminality mohou souviset například s hospodářským vývojem, nezaměstnaností, urbanizací nebo technologickým pokrokem (**Becker, 1968; Eurostat, 2024**). Časové řady kriminality proto umožňují sledovat, zda jednotlivé státy vykazovat obdobné vývojové trajektorie, což je klíčové při zkoumání konvergence v rámci Evropské unie.

Z metodologického hlediska je vhodné rozlišovat mezi **trendovou a krátkodobou složkou** časové řady. Dlouhodobý trend může signalizovat strukturální změny, zatímco krátkodobé výkyvy mohou být důsledkem přechodných ekonomických šoků, legislativních změn nebo změn v metodice evidence (**Eurostat, 2024; UNODC, 2015**). Rozlišení těchto složek je nezbytné pro správnou interpretaci konvergenčních procesů, aby nedocházelo k záměně dočasných efektů za skutečné dlouhodobé sbližování (**Barro & Sala-i-Martin, 2004**).

V ekonometrické literatuře bývá analýza časových řad spojována s pojmy jako **stacionarita, autokorelace nebo strukturální zlom**. Tyto koncepty upozorňují, že hodnoty v jednotlivých obdobích nejsou nezávislé, ale navazují na předchozí vývoj (**Hastie et al., 2009**). V kombinaci s metodami strojového učení umožňuje analýza časových řad sledovat i vývoj struktury kriminality, například prostřednictvím hodnocení, zda se státy v průběhu času přesouvají mezi identifikovanými shluky (**James et al., 2021**).

Časová dimenze tak tvoří významný prvek empirické analýzy této práce a doplňuje statické pohledy založené na průřezových datech. Zatímco průřezová analýza zachycuje podobnosti mezi státy v určitém okamžiku, časové řady umožňují porozumět samotnému procesu změny. V této práci je analýza časových řad využita zejména při hodnocení vývoje variability kriminality v období 2013–2023.

2.4 Využití strojového učení v kriminologickém výzkumu

Využití metod strojového učení v kriminologickém výzkumu se v posledních letech postupně rozšiřuje, a to zejména v souvislosti s rostoucí dostupností rozsáhlých a detailních datových souborů, vyšší výpočetní kapacitou a digitalizací veřejné správy. Tradiční statistické metody často narážejí na limity v podobě silných modelových předpokladů, zatímco algoritmy strojového učení dokážou identifikovat komplexní nelineární vzorce v datech. V současné kriminologii lze identifikovat čtyři hlavní oblasti aplikace těchto metod.

2.4.1 Prediktivní policing a analýza hotspotů

Významnou oblastí je práce s geografickými daty, kde algoritmy pomáhají identifikovat tzv. hotspoty – místa s vysokou koncentrací kriminality. Moderní kriminologie v této oblasti využívá teorii „near-repeat“ (blízkého opakování), která předpokládá, že spáchání trestného činu na určitém místě zvyšuje riziko dalšího incidentu v bezprostředním okolí (**Mohler et al., 2015**).

Konkrétním příkladem aplikace je algoritmus **PredPol** (Predictive Policing), který využívá metodu procesů bodového měření (Hawkes processes) k modelování seismické aktivity aplikovanou na kriminální incidenty. Tento systém umožňuje policii efektivněji alokovat hlídky do oblastí s nejvyšším predikovaným rizikem v reálném čase. Další techniky, jako jsou náhodné lesy (Random Forests) nebo Support Vector Machines (SVM), se využívají k predikci typu trestné činnosti na základě environmentálních faktorů, jako je osvětlení, hustota zástavby nebo blízkost barů (**Al Boni et al., 2016**).

2.4.2 Hodnocení rizik a predikce recidivy

Metody učení s učitelem nacházejí široké uplatnění při tvorbě nástrojů pro hodnocení rizik (risk assessment tools), které pomáhají soudům a vězeňské správě odhadovat pravděpodobnost recidivy u pachatelů. Tradiční metody jsou doplňovány nebo nahrazovány algoritmy, jako je gradientní boosting (XGBoost), které dosahují vyšší predikční přesnosti díky schopnosti zpracovat stovky proměnných včetně demografických a socioekonomických ukazatelů (**Berk, 2017**).

Nejznámějším, byť kontroverzním příkladem, je systém **COMPAS** (Correctional Offender Management Profiling for Alternative Sanctions), který využívá algoritmy k hodnocení rizikovosti pachatele. Tato aplikace ML však otevřela zásadní diskusi o etice a systémové podjatosti (biasu), neboť data používaná k učení modelů mohou v sobě nést historické rasové či sociální předsudky (**Angwin et al., 2016**).

2.4.3 Detekce anomálií a finanční kriminalita

V oblasti ekonomické kriminality a kyberkriminality se uplatňují především metody učení bez učitele (unsupervised learning). Tyto techniky umožňují identifikovat podezřelé transakce nebo anomální chování, které se odchyluje od běžných vzorců, aniž by bylo předem známo, co přesně představuje podvod. Využívají se zde zejména:

- **Shluková analýza (Clustering):** Seskupování účtů nebo transakcí s cílem odhalit sítě pro praní špinavých peněz.
- **Izolační lesy (Isolation Forests):** Algoritmus efektivní pro detekci osamocených anomálií ve velkých datových souborech.
- **Analýza sociálních sítí (SNA):** Využívaná k mapování organizační struktury organizovaného zločinu a identifikaci klíčových aktérů v kriminálních skupinách (Tayebi & Glässer, 2016).

2.4.4 Strukturální srovnání a konvergenční studie

Metody bez učitele, jako je shluková analýza K-means a analýza hlavních komponent (PCA), jsou klíčové pro mezinárodní komparativní výzkum (James et al., 2021). Umožňují odhalovat latentní struktury a rozdělovat státy či regiony do skupin s podobnou skladbou trestné činnosti, aniž by výzkumník musel předem definovat rigidní kategorie. Právě tento přístup je základem pro zkoumání konvergence, neboť umožňuje sledovat, zda se státy v čase přesouvají mezi shluky, což indikuje strukturální změny v kriminalitě dané země (Hastie et al., 2009).

2.4.5 Metodologické a etické limity

I přes vysokou efektivitu ML metod je nutné zdůraznit, že jejich výsledky jsou kriticky závislé na kvalitě vstupních dat. V kriminologii je tento problém umocněn fenoménem „temné cifry“ kriminality a rozdílnou metodikou evidence mezi státy (Eurostat, 2024). Identifikované vzorce proto nesmí být chápány jako automatické důkazy kauzality, ale jako analytické nástroje, které vyžadují interpretaci v teoretickém a historickém kontextu. Z tohoto důvodu je v akademickém prostředí preferována transparentnost a využívání interpretovatelných modelů před tzv. „black-box“ systémy (James et al., 2021).

3 Data a metodika zpracování

Tato kapitola popisuje použité datové zdroje, konstrukci jednotlivých datových sad a metodologický postup využitý při empirické analýze konvergence kriminality v Evropské unii. Jejím cílem je transparentně vymezit, z jakých dat práce vychází, jakým způsobem byla data upravena a očištěna a jaké analytické kroky byly realizovány před samotnou aplikací konvergenčních testů a metod strojového učení.

Nejprve jsou představeny hlavní použité datové zdroje, zejména oficiální statistiky kriminality publikované databází **Eurostat (2024)** a doplňkové socioekonomické ukazatele. Následně je popsán proces konstrukce datových sad, včetně výběru proměnných, časového období a jednotek analýzy. Pozornost je věnována rovněž čištění dat, ošetření chybějících hodnot a standardizaci proměnných, které jsou nezbytné pro zajištění srovnatelnosti mezi členskými státy Evropské unie s odlišnými měřítky ukazatelů (**James et al., 2021**).

Další část kapitoly se zaměřuje na explorační analýzu dat a formulaci výzkumných otázek a hypotéz, které vycházejí z teoretických východisek uvedených v předchozích kapitolách. Součástí metodologického postupu je také zdůvodnění volby jednotlivých analytických metod a jejich vhodnosti pro zkoumaný problém.

Závěrečná část kapitoly popisuje implementaci analytického procesu v programovém prostředí **Python**, s využitím specializovaných knihoven pro datovou vědu a strojové učení, jako jsou *pandas*, *scikit-learn* nebo *matplotlib* (**James et al., 2021; Pedregosa et al., 2011**). Tato kapitola tak vytváří komplexní metodologický rámec pro následnou empirickou analýzu konvergence kriminality v Evropské unii.

3.1 Použité datové zdroje

Empirická analýza konvergence kriminality v této práci vychází primárně ze sekundárních dat publikovaných statistickým úřadem Evropské unie **Eurostat**. Hlavním zdrojem jsou roční údaje o policií evidovaných trestných činech podle mezinárodní klasifikace **ICCS** (International Classification of Crime for Statistical Purposes), které umožňují srovnání jednotlivých kategorií kriminality napříč členskými státy Evropské unie (**Eurostat, 2024a; UNODC, 2015**).

Data jsou strukturována podle zemí, let a typů trestných činů a pokrývají období od roku 2010 do nejnovějšího dostupného roku. Pro účely této práce bylo analyzováno především období **2013–2023**, které poskytuje dostatečně dlouhou časovou řadu a současně zahrnuje relativně aktuální vývoj kriminality v Evropské unii.

Pro mezinárodní srovnání byla data o absolutním počtu trestných činů doplněna demografickými údaji, zejména o počtu obyvatel, rovněž převzatými z databází Eurostatu. Tyto údaje umožňují **přepočet kriminality na 100 000 obyvatel**, čímž se eliminuje vliv

rozdílné velikosti populace jednotlivých států a zvyšuje se srovnatelnost mezi zeměmi (**Eurostat, 2024a**). Jako doplňkový socioekonomický ukazatel byl využit hrubý domácí produkt na obyvatele (HDP na obyvatele), který slouží jako aproximace ekonomické úrovně a životních podmínek (**Eurostat, 2024b**).

Přesto je nutné zohlednit určitá omezení těchto dat. Mezi hlavní patří rozdíly v národních právních definicích trestných činů, rozdílná míra hlášení kriminality, odlišná efektivita policejních složek a variabilní způsoby evidence jednotlivých deliktů. Evidovaná kriminalita proto nemusí vždy plně odpovídat skutečnému rozsahu trestné činnosti (tzv. temná cifra) (**Eurostat, 2024a; UNODC, 2015**).

Z tohoto důvodu jsou výsledky práce interpretovány s metodologickou opatrností. Datové zdroje Eurostatu jsou vhodné pro analýzu relativních rozdílů a dlouhodobých trendů mezi státy, nikoliv však jako absolutně přesný obraz reálné kriminality v jednotlivých zemích Evropské unie.

3.2 Konstrukce datové sady

Konstrukce datové sady vychází z požadavku na **panelovou strukturu dat**, která umožňuje sledovat vývoj kriminality v jednotlivých státech Evropské unie v čase a následně aplikovat jak konvergenční testy, tak vícerozměrné metody strojového učení. Panelová data kombinují časovou a průřezovou dimenzi, což umožňuje analyzovat nejen rozdíly mezi státy, ale také jejich vnitřní dynamiku vývoje (**Barro & Sala-i-Martin, 2004; James et al., 2021**).

Základní jednotkou pozorování je dvojice (stát, rok), ke které jsou přiřazeny hodnoty kriminality pro vybrané kategorie trestné činnosti a doplňkové socioekonomické ukazatele. Primární datová část je tvořena ročními údaji o policií evidovaných trestných činech podle klasifikace **ICCS** (International Classification of Crime for Statistical Purposes). Pro zajištění mezinárodní srovnatelnosti byla kriminalita vyjádřena v přepočtu na **100 000 obyvatel**, což je v komparativních kriminologických studiích standardním postupem pro eliminaci vlivu rozdílné velikosti populace (**Eurostat, 2024a; UNODC, 2015**).

Data byla následně omezena na členské státy Evropské unie (EU-27) a na období **2013–2023**. Toto časové vymezení bylo zvoleno z důvodu metodické konzistence dat a relevance pro současný vývoj kriminality. Do panelové datové sady byl dále doplněn ukazatel **HDP na obyvatele**, který slouží jako základní aproximace ekonomické úrovně států (**Eurostat, 2024b**). Hodnoty byly k jednotlivým rokům přiřazeny prostřednictvím spojení dat (*merge*) podle klíčových proměnných *country* a *year*.

Vzhledem k tomu, že kriminalita představuje vícerozměrný jev, byla v další fázi analýzy využita také reprezentace založená na tzv. **profilu kriminality**. Pro každý stát a rok lze kriminalitu chápat jako vektor hodnot jednotlivých kategorií trestné činnosti. Tato reprezentace je vhodná zejména pro výpočet vzdáleností mezi státy a následnou aplikaci metod bez učitele, jako je shluková analýza nebo redukce dimenzionality pomocí PCA (**James et al., 2021**).

Výsledkem tohoto procesu je integrovaná datová sada připravená pro testování sigma – a beta-konvergence i pro pokročilou identifikaci skupin států s obdobným vývojem bezpečnostní situace.

3.3 Čištění a předzpracování dat

Před samotnou aplikací konvergenčních testů a metod strojového učení bylo nezbytné provést systematické čištění a předzpracování dat. Vzhledem k tomu, že analyzovaná data pocházejí z mezinárodní statistické databáze a zahrnují více států i časových období, představuje zajištění konzistence a srovnatelnosti klíčový krok celého analytického postupu (**James et al., 2021**).

Proces předzpracování zahrnoval zejména sjednocení názvů proměnných, převod datových typů do numerické podoby a filtraci relevantních jednotek. Zvláštní pozornost byla věnována zachování mezinárodní srovnatelnosti. Z tohoto důvodu byla kriminalita vyjádřena v přepočtu na **100 000 obyvatel**, což eliminuje vliv rozdílné velikosti populace a je standardním postupem v komparativní kriminologii (**Eurostat, 2024a; UNODC, 2015**).

V rámci čištění dat byly odstraněny agregované územní celky (např. souhrnné ukazatele EU) a analýza byla zaměřena výhradně na členské státy **EU-27**. Součástí procesu byla také kontrola duplicity záznamů a základní validace extrémních hodnot, aby bylo zajištěno, že pro každou dvojici (stát, rok) existuje validní pozorování (**Hastie et al., 2009**).

Předzpracování dat bylo realizováno v programovacím prostředí **Python** s využitím knihovny **pandas** pro efektivní manipulaci s tabulkovými daty a knihovny **NumPy** pro numerické operace (**Harris et al., 2020; McKinney, 2010**).

Výsledkem tohoto procesu je konzistentní panelová datová sada připravená pro výpočet ukazatelů sigma – a beta-konvergence a následnou aplikaci metod bez učitele. Podrobnější postup ošetření chybějících hodnot a standardizace proměnných je popsán v následujících podkapitolách.

3.3.1 Ošetření chybějících hodnot

Při zpracování dat z databáze Eurostat se mohou vyskytovat chybějící hodnoty a nekonzistentní záznamy, a to jak v důsledku neúplného reportování jednotlivých států, tak vlivem rozdílů v metodice evidence nebo změn klasifikace v čase. Z tohoto důvodu byla před samotnou analýzou provedena standardizace datových typů a konzervativní ošetření chybějících hodnot (**James et al., 2021**).

V rámci předzpracování byly proměnné *year* a příslušné numerické ukazatele převedeny do číselného formátu s využitím převodu tolerantního k chybám. Neplatné, textové nebo jinak nestrukturované hodnoty byly transformovány na chybějící hodnoty

(NaN). Následně byly všechny záznamy s chybějícími hodnotami u klíčových proměnných odstraněny (**Hastie et al., 2009**).

U datasetu kriminality byla nejprve provedena filtrace na jednotku vyjádření na 100 000 obyvatel, aby byla zajištěna mezinárodní srovnatelnost (**Eurostat, 2024a; UNODC, 2015**). Následně byly ponechány pouze klíčové proměnné:

- *country*
- *year*
- *offence*
- *crime_rate*

Poté byly odstraněny záznamy obsahující chybějící hodnotu v některém z těchto atributů. Analogický postup byl aplikován také u datasetu HDP na obyvatele, kde byly ponechány proměnné:

- *country*
- *year*
- *gdp_index*

I v tomto případě byly následně odstraněny nekompletní záznamy. Současně byla u obou datasetů provedena filtrace na členské státy **EU-27** a na časové období **2013–2023**, čímž se zvýšila konzistence výsledného panelu.

V této práci nebyly aplikovány metody **imputace chybějících hodnot** (např. lineární interpolace). Důvodem je skutečnost, že tyto postupy mohou uměle snižovat variabilitu ukazatelů v čase a tím zkreslovat výsledky testování sigma- i beta-konvergence (**Barro & Sala-i-Martin, 2004**). Zvolený postup je proto metodicky konzervativní; analýza pracuje výhradně s reálně pozorovanými hodnotami (**James et al., 2021**).

3.3.2 Normalizace a transformace proměnných

Pro zajištění srovnatelnosti dat a správné aplikace statistických i analytických metod byly na výslednou datovou sadu aplikovány vybrané transformace proměnných. Tyto úpravy reflektují jak specifika kriminality jako sledovaného jevu, tak metodologické požadavky jednotlivých postupů použitých v empirické části práce (**James et al., 2021**).

Základní normalizace kriminality byla zajištěna již na úrovni vstupních dat, kde byly využity ukazatele vyjádřené jako počet trestných činů na 100 000 obyvatel. Tento přepoččet eliminuje vliv rozdílné velikosti populace jednotlivých států a umožňuje jejich přímé mezinárodní srovnání (**Eurostat, 2024a; UNODC, 2015**).

Pro účely konvergenční analýzy byla dále aplikována logaritmická transformace vybraných proměnných, zejména míry kriminality a HDP na obyvatele. Logaritmování proměnných je v empirickém výzkumu běžně využíváno, protože:

- zmírňuje vliv extrémních hodnot,
- redukuje asymetrii rozdělení dat,
- stabilizuje rozptyl proměnných,
- umožňuje interpretaci výsledků v relativních (procentních) změnách (**Barro & Sala-i-Martin, 2004; James et al., 2021**).

Tento přístup je standardní zejména při testování beta-konvergence a regresních vztahů mezi ekonomickými ukazateli (**Barro & Sala-i-Martin, 2004**).

V případě metod strojového učení, zejména shlukové analýzy a metod redukce dimenze, byla data následně standardizována pomocí **z-skóre**. U každé proměnné byl odečten průměr a výsledek vydělen směrodatnou odchylkou. Tím bylo dosaženo nulového průměru a jednotkového rozptylu (**James et al., 2021**).

Standardizace je důležitá zejména proto, že:

- jednotlivé proměnné mají rozdílné měřítko,
- bez standardizace by proměnné s vyšší variabilitou nepřiměřeně ovlivňovaly výsledek,
- vzdálenostní metriky (např. eukleidovská vzdálenost) jsou citlivé na rozsah hodnot (**Hastie et al., 2009; James et al., 2021**).

Tento krok byl proto nezbytný pro správnou identifikaci podobností mezi státy Evropské unie. Naopak nebyl konstruován agregovaný index kriminality, který by spojoval jednotlivé typy trestné činnosti do jedné syntetické proměnné. Takový postup by sice vedl ke zjednodušení analýzy, avšak současně by znamenal ztrátu informací o vnitřní struktuře kriminality a rozdílném vývoji jednotlivých kategorií trestných činů.

V této práci je proto kriminalita chápána jako vícerozměrný jev, kde jednotlivé kategorie trestné činnosti tvoří soubor charakteristik daného státu. Tento přístup umožňuje detailnější analýzu konvergence i přesnější identifikaci strukturálních podobností mezi státy. Zvolený systém transformací dat tak umožnil vhodně propojit tradiční statistické přístupy s metodami strojového učení při zachování vysoké informační hodnoty vstupních dat.

3.4 Explorační analýza dat (EDA)

Explorační analýza dat (Exploratory Data Analysis, EDA) představuje důležitý mezikrok mezi předzpracováním dat a samotnou aplikací analytických metod. Jejím hlavním cílem je získat základní přehled o struktuře dat, identifikovat dominantní vzorce a trendy a současně odhalit případné anomálie, které by mohly ovlivnit výsledky následné empirické analýzy (**James et al., 2021**).

V této práci je explorační analýza zaměřena především na vývoj kriminality v jednotlivých členských státech Evropské unie v čase a na porovnání vybraných kategorií trestné činnosti. Zvláštní pozornost je věnována čtyřem typům kriminality: úmyslným vraždám, loupežím, vloupáním do soukromých obydlí a trestným činům souvisejícím s drogami. Tyto kategorie byly zvoleny s ohledem na jejich společenskou relevanci, datovou dostupnost a relativní srovnatelnost napříč členskými státy (**Eurostat, 2024a; UNODC, 2015**).

V první fázi EDA byly analyzovány základní charakteristiky datového souboru, zejména:

- počet států zahrnutých do analýzy,
- počet sledovaných let,
- rozsah dostupných kategorií kriminality,
- úplnost dat v jednotlivých obdobích,
- základní statistické charakteristiky proměnných (**Hastie et al., 2009**).

Následně byl zkoumán vývoj míry kriminality v čase, a to jak na úrovni jednotlivých států, tak agregovaně napříč Evropskou unií. Tato část analýzy umožnila identifikovat dlouhodobé trendy, období stability i možné strukturální zlomy ve vývoji sledovaných ukazatelů.

Významnou součástí explorační analýzy bylo rovněž sledování variability kriminality mezi státy, které bylo realizováno prostřednictvím vývoje směrodatné odchylky v čase. Tento ukazatel poskytuje první indikaci možných konvergenčních procesů (**Barro & Sala-i-Martin, 2004**):

- **klesající variabilita** může naznačovat sblížování úrovně kriminality mezi státy (sigma-konvergence),
- **rostoucí variabilita** může signalizovat divergenci,
- **stabilní variabilita** může indikovat dlouhodobě neměnnou strukturu rozdílů mezi státy.

Součástí EDA bylo také vizuální porovnání jednotlivých kategorií kriminality, které umožnilo sledovat, zda se různé formy trestné činnosti vyvíjejí podobně, nebo zda vykazují odlišnou dynamiku. Veškeré vizualizace byly vytvořeny v programovacím prostředí **Python**, zejména s využitím knihovny **matplotlib**, případně doplňkově knihoven **pandas** a **seaborn** (**Hunter, 2007; McKinney, 2010; Waskom, 2021**). Výstupy zahrnovaly:

- časové řady vývoje kriminality,
- porovnání států v jednotlivých letech,
- grafy směrodatné odchylky,
- souhrnné komparativní grafy vybraných kategorií trestné činnosti.

Explorační analýza dat tak v této práci plní dvojí funkci. Jednak slouží jako kontrolní mechanismus kvality dat a jednak poskytuje první intuitivní vhled do dynamiky kriminality v Evropské unii. Získaná zjištění následně tvoří základ pro formulaci výzkumných otázek, hypotéz a aplikaci formálních metod konvergenční analýzy v následujících částech práce.

3.5 Návrh výzkumných otázek a hypotéz

Na základě teoretických východisek představených v předchozích kapitolách (**Barro & Sala-i-Martin, 2004; James et al., 2021**) a výsledků explorační analýzy dat jsou v této práci formulovány výzkumné otázky a hypotézy směřující k posouzení konvergence kriminality v Evropské unii po roce 2010. Důraz je kladen jak na celkovou úroveň kriminality, tak na její vnitřní strukturu a rozdíly mezi jednotlivými kategoriemi trestné činnosti (**Eurostat, 2024a; UNODC, 2015**).

3.5.1 Výzkumné otázky

Hlavní výzkumná otázka této práce zní:

- **Dochází po roce 2010 ke konvergenci kriminality mezi státy Evropské unie?**

Tato hlavní otázka je dále rozpracována do několika dílčích výzkumných otázek:

- Dochází ke snižování rozdílů v míře kriminality mezi státy Evropské unie, tedy k přítomnosti **sigma-konvergence**?
- Vykazují státy s vyšší počáteční úrovní kriminality rychlejší pokles kriminality než státy s nižší výchozí úrovní, tedy je přítomna **beta-konvergence**?
- Existují mezi členskými státy skupiny zemí s podobnou strukturou kriminality a jsou tyto skupiny v čase stabilní?
- Liší se vývoj a intenzita konvergence mezi jednotlivými kategoriemi trestné činnosti?
- Do jaké míry souvisí vývoj kriminality se socioekonomickými charakteristikami států, zejména s úrovní HDP na obyvatele?

3.5.2 Hypotézy

Na základě uvedených výzkumných otázek a teoretických konceptů (**Barro & Sala-i-Martin, 2004; James et al., 2021**) jsou formulovány následující pracovní hypotézy:

- **H1:** Mezi státy Evropské unie dochází ke **sigma-konvergenci** kriminality, tedy ke snižování variability kriminality v čase.

- **H2:** Existuje **beta-konvergence** kriminality, kdy státy s vyšší počáteční úrovní kriminality vykazují v následujícím období rychlejší pokles (**Barro & Sala-i-Martin, 2004**).
- **H3:** Struktura kriminality mezi členskými státy není homogenní a lze identifikovat **shluky států** s podobným profilem kriminality (**James et al., 2021**).
- **H4:** Dynamika konvergence se liší mezi jednotlivými kategoriemi trestné činnosti, přičemž některé typy kriminality vykazují vyšší míru sbližování než jiné.
- **H5:** Vyspělejší státy s vyšší ekonomickou úrovní vykazují odlišný profil kriminality než státy s nižší úrovní HDP na obyvatele (**Becker, 1968; Eurostat, 2024b**).

Formulované hypotézy budou ověřovány kombinací tradičních statistických metod a metod strojového učení:

- **Hypotéza H1** bude testována pomocí analýzy vývoje směrodatné odchylky a variačního koeficientu v čase (**Barro & Sala-i-Martin, 2004**).
- **Hypotéza H2** bude ověřena regresní analýzou beta-konvergence.
- **Hypotézy H3 a H5** budou analyzovány prostřednictvím shlukové analýzy a interpretace výsledných skupin států (**James et al., 2021**).
- **Hypotéza H4** bude posouzena porovnáním výsledků mezi jednotlivými kategoriemi kriminality (**Eurostat, 2024a; UNODC, 2015**).

Takto formulovaný výzkumný rámec umožňuje zachytit nejen celkové trendy sbližování kriminality v Evropské unii, ale také její strukturální rozdíly a specifika jednotlivých forem trestné činnosti.

3.6 Implementace analytického postupu

V této kapitole je popsán konkrétní postup implementace analytické části práce, včetně použitých nástrojů, knihoven a jednotlivých kroků zpracování dat. Empirická analýza byla realizována v programovacím jazyce **Python**, který představuje standardní nástroj pro moderní datovou analýzu a umožňuje efektivní práci s rozsáhlými datovými soubory i aplikaci statistických a strojově-učících metod (**McKinney, 2010; James et al., 2021**).

Pro realizaci analýzy byly využity zejména následující knihovny:

- **pandas** – práce s tabulkovými daty a jejich transformace (**McKinney, 2010**),
- **numpy** – numerické operace a výpočty (**Harris et al., 2020**),
- **matplotlib** a **seaborn** – tvorba grafů a vizualizací (**Hunter, 2007; Waskom, 2021**),

- **scikit-learn** – implementace metod strojového učení, jako jsou K-means, PCA a standardizace (**Pedregosa et al., 2011**),
- **statsmodels** – regresní modelování a statistické testování beta-konvergence (**Seabold & Perktold, 2010**).

Analytický postup byl rozdělen do několika navazujících kroků:

3.6.1 Načtení a příprava dat

V prvním kroku byla načtena vstupní data o kriminalitě a ekonomických ukazatelích z externích datových souborů získaných z databáze **Eurostat (2024a)**. Následně byla provedena úprava struktury datasetů, sjednocení názvů proměnných a převod datových typů do numerické podoby. Současně byla provedena filtrace na členské státy Evropské unie, omezení časového období na roky 2013–2023, odstranění nekompletních záznamů a logaritmická transformace vybraných proměnných pro stabilizaci rozptylu (**Barro & Sala-i-Martin, 2004**).

3.6.2 Kontrola kvality dat

Ve druhém kroku byla provedena základní kontrola kvality dat (*sanity checks*), jejímž cílem bylo ověřit správnost vstupních datasetů. Kontrolovány byly zejména počty zahrnutých států, sledovaných let a kategorií trestné činnosti, dále konzistence názvů států, přítomnost chybějících hodnot a duplicity pozorování (**James et al., 2021**).

3.6.3 Výběr kategorií kriminality

Klíčovou část implementace představovala analýza sigma-konvergence, realizovaná výpočtem variability kriminality mezi státy. Pro každou kategorii byla vypočtena směrodatná odchylka a variační koeficient, přičemž trend jejich vývoje v čase byl interpretován jako důkaz sblížování či divergence (**Barro & Sala-i-Martin, 2004**).

3.6.4 Analýza sigma-konvergence

Klíčovou část implementace představovala analýza sigma-konvergence, realizovaná výpočtem variability kriminality mezi státy. Pro každou kategorii byla vypočtena směrodatná odchylka a variační koeficient, přičemž trend jejich vývoje v čase byl interpretován jako důkaz sblížování či divergence (**Barro & Sala-i-Martin, 2004**).

3.6.5 Regresní analýza beta-konvergence

Testování beta-konvergence bylo provedeno pomocí lineárního regresního modelu, kde změna kriminality byla vysvětlována její počáteční úrovní. Model byl odhadnut pomocí knihovny **statsmodels**, která umožnila získat regresní koeficienty, hodnoty p-value, koeficient determinace R^2 a intervaly spolehlivosti (**Seabold & Perktold, 2010**).

3.6.6 Shluková analýza a PCA

Pro identifikaci strukturálních podobností byla aplikována shluková analýza **K-means** na datech standardizovaných pomocí z-skóre. Optimální počet shluků byl stanoven metodou lokte (*elbow method*). Výsledné clustery byly vizualizovány prostřednictvím metody **PCA** (Principal Component Analysis) pro převod vícerozměrných dat do dvourozměrného prostoru (**James et al., 2021**).

3.6.7 Vizualizace výstupů

Grafické výstupy byly vytvářeny pomocí knihovny **matplotlib**. Vytvořeny byly zejména časové řady sigma-konvergence, regresní grafy beta-konvergence, PCA mapy shluků a souhrnné komparativní grafy (**Hunter, 2007**).

3.6.8 Reprodukovatelnost a modularita řešení

Celý analytický proces byl navržen modulárně, kdy byly jednotlivé části (čištění, výpočty, modelování, vizualizace) odděleny do samostatných skriptů. Tento přístup zvyšuje přehlednost, usnadňuje kontrolu jednotlivých kroků a zajišťuje plnou reprodukovatelnost výsledků. Využití prostředí Python tak umožnilo realizovat kompletní proces transparentním a metodologicky vhodným způsobem.

4 Empirická analýza konvergence kriminality v EU z vlastního výzkumu

Tato kapitola prezentuje výsledky empirického výzkumu zaměřeného na analýzu konvergence kriminality mezi členskými státy Evropské unie. Analýza vychází z dat dostupných v databázi **Eurostat (2024a)** a z metodologického postupu popsáno v předchozí kapitole. Současně kombinuje tradiční konvergenční přístupy s prvky vícerozměrné datové analýzy (**Barro & Sala-i-Martin, 2004; James et al., 2021**).

Hlavním cílem této kapitoly je ověřit, zda po roce 2010 dochází ke konvergenci, nebo naopak divergenci úrovně kriminality mezi státy Evropské unie, a to nejen na úrovni jednotlivých kategorií trestné činnosti, ale také z hlediska jejich širší struktury. Důraz je kladen především na **sigma-konvergenci**, tedy vývoj variability kriminality mezi státy v čase, a dále na identifikaci rozdílů mezi jednotlivými typy kriminality (**Barro & Sala-i-Martin, 2004**).

Analýza je členěna do několika navazujících částí:

- Nejprve je zkoumán celkový vývoj kriminality v čase a základní charakteristiky vybraných kategorií trestné činnosti (**UNODC, 2015**).
- Následně jsou prezentovány výsledky **sigma-konvergence**, které umožňují posoudit, zda dochází ke snižování rozdílů mezi členskými státy.
- V další části kapitoly je pozornost věnována strukturální podobnosti mezi státy a identifikaci skupin zemí s obdobným profilem kriminality prostřednictvím **shlukové analýzy (James et al., 2021)**.
- Závěrečná část kapitoly se zaměřuje na interpretaci získaných výsledků ve vztahu k teoretickým východiskům a formulovaným hypotézám.

Tato kapitola představuje stěžejní empirickou část celé práce, neboť v ní dochází k aplikaci navržených analytických metod na reálná data a k odpovědi na hlavní výzkumnou otázku týkající se konvergence kriminality v Evropské unii.

4.1 Vývoj kriminality v zemích EU v čase


Pro účely analýzy vývoje kriminality v členských státech Evropské unie je v této práci využito sledování variability zkoumaných dat v čase. Ke kvantifikaci rozdílů mezi jednotlivými státy byla použita směrodatná odchylka míry kriminality na 100 000 obyvatel (**Eurostat, 2024a**). Tento ukazatel umožňuje objektivně posoudit, zda v referenčním období 2013–2023 dochází ke sbližování úrovně kriminality mezi státy (sigma-

konvergence), nebo naopak k prohlubování rozdílů (divergence) (**Barro & Sala-i-Martin, 2004**).

4.1.1 Celkový vývoj napříč kategoriemi

Při vyhodnocení jednotlivých kategorií trestné činnosti bylo zjištěno, že vývoj kriminality nevykazuje jednotný charakter. Naopak byly identifikovány rozdílné trendy podle typu sledované kriminality (**Eurostat, 2024a; UNODC, 2015**). Z tohoto důvodu nelze konvergenci kriminality v Evropské unii chápat jako univerzální a homogenní proces. Analyticky je vhodnější ji interpretovat jako soubor dílčích vývojových procesů, které se mezi jednotlivými kategoriemi trestné činnosti významně liší (**Barro & Sala-i-Martin, 2004; James et al., 2021**).

Graf 1: Vývoj sigma-konvergence napříč vybranými kategoriemi kriminality v zemích EU-27 v letech 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.1.2 Vloupání do soukromých obydlí

Nejvýraznější trend sigma-konvergence byl identifikován u kategorie vloupání do soukromých obydlí (**Eurostat, 2024a**). Ve sledovaném období docházelo k postupnému poklesu směrodatné odchylky mezi státy, což indikuje snižování rozdílů v úrovni tohoto typu kriminality napříč Evropskou unií (**Barro & Sala-i-Martin, 2004**).


Po roce 2020 bylo patrné určité zpomalení tohoto trendu a relativní stabilizace variability, nicméně bez návratu k původním vyšším hodnotám. Výsledek lze interpretovat

jako poměrně robustní důkaz probíhající sigma-konvergence v oblasti majetkové kriminality (**Eurostat, 2024a; James et al., 2021**).

Tento vývoj může souviset zejména s:

- rozšířením preventivních bezpečnostních technologií,
- vyšší standardizací zabezpečení obydlí,
- sdílením osvědčených postupů mezi státy,
- změnami životního stylu a digitalizací společnosti (**UNODC, 2015**).

Graf 2: Vývoj sigma-konvergence u vloupání do soukromých obydlí v zemích EU-27 v letech 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.1.3 Loupeže


U kategorie loupeží byl zaznamenán obdobný, avšak méně výrazný trend (**Eurostat, 2024a**). V první polovině sledovaného období docházelo ke snižování variability mezi státy, což naznačuje sbližování úrovní této kriminality (**Barro & Sala-i-Martin, 2004**).

Po roce 2020 byl však patrný mírný nárůst rozptylu, který může znamenat částečné narušení předchozího konvergenčního trendu (**James et al., 2021**).

Celkově lze konstatovat, že u loupeží existují známky sigma-konvergence, avšak s nižší stabilitou než u vloupání do obydlí. Vývoj mohl být ovlivněn zejména:

- krátkodobými ekonomickými výkyvy,
- změnami sociální situace obyvatelstva,
- dopady pandemického období,
- lokálními bezpečnostními šoky (**UNODC, 2015**).

Graf 3: Vývoj sigma-konvergence u loupeží v zemích EU-27 v letech 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.1.4 Úmyslné vraždy

V případě úmyslných vražd byla dlouhodobě identifikována velmi nízká variabilita mezi státy Evropské unie. Ve sledovaném období došlo pouze k mírnému dalšímu poklesu rozptylu (**Eurostat, 2024a**).


Tento výsledek naznačuje slabou formu **sigma-konvergence**, avšak především potvrzuje, že členské státy Evropské unie již v současnosti vykazují relativně podobné hodnoty tohoto typu kriminality (**Barro & Sala-i-Martin, 2004; UNODC, 2015**).

Nízká variabilita může souviset s:

- vysokou institucionální kontrolou násilné kriminality,
- podobnou úrovní trestněprávních systémů,
- dlouhodobým poklesem násilné kriminality v Evropě,

- relativně nízkou frekvencí tohoto jevu obecně (**UNODC, 2015**).

Graf 4: Vývoj sigma-konvergence u úmyslných vražd v zemích EU-27 v letech 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.1.5 Drogová kriminalita


Zcela odlišný vývoj byl zaznamenán u trestné činnosti související s drogami (**Eurostat, 2024a**). V první části analyzovaného období docházelo k růstu variability mezi státy, přičemž nejvyšších hodnot bylo dosaženo přibližně kolem roku 2020.

Tento trend indikuje **divergenci**, tedy prohlubování rozdílů mezi státy (**Barro & Sala-i-Martin, 2004**). V následujících letech sice došlo k mírnému poklesu variability, její úroveň však zůstala ve srovnání s ostatními kategoriemi vysoká (**James et al., 2021**).

Proces konvergence je v této oblasti slabý a nestabilní. Důvodem mohou být zejména:

- rozdílné národní přístupy k drogové politice,
- odlišná intenzita policejního vymáhání,
- rozdílné právní definice drogových deliktů,
- metodologické rozdíly ve sběru dat (**UNODC, 2015**).

Graf 5: Vývoj sigma-konvergence u trestných činů souvisejících s drogami v zemích EU-27 v letech 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.1.6 Shrnutí výsledků

Na základě získaných výsledků lze konstatovat, že sigma-konvergence kriminality v Evropské unii není univerzálním jevem (**Barro & Sala-i-Martin, 2004**).

- U některých kategorií, zejména majetkové kriminality, byla identifikována poměrně silná tendence ke sbližování mezi státy (**Eurostat, 2024a**).
- U jiných kategorií, především drogové kriminality, přetrvávají výrazné rozdíly (**UNODC, 2015**).
- U úmyslných vražd je variabilita již dlouhodobě nízká (**Eurostat, 2024a**).

Výsledky tedy poskytují první odpověď na hlavní výzkumnou otázku této práce. **Hypotézu H1**, předpokládající existenci sigma-konvergence kriminality mezi státy Evropské unie, lze **potvrdit pouze částečně**, přičemž její platnost je podmíněna konkrétní kategorií trestné činnosti (**James et al., 2021**).

4.2 Výsledky shlukové analýzy

Za účelem identifikace skupin států s obdobným profilem kriminality byla na analyzovaný dataset aplikována shluková analýza využívající algoritmus K-means. Cílem této části analýzy bylo zjistit, zda lze členské státy Evropské unie rozdělit do relativně


homogenních skupin na základě podobnosti jejich kriminalitních a socioekonomických charakteristik (James et al., 2021).

V rámci předzpracování byla vstupní data nejprve agregována na průměrné hodnoty za referenční období 2013–2023. Agregace byla provedena pro vybrané kategorie trestné činnosti, konkrétně úmyslné vraždy, loupeže, vloupání do soukromých obydlí a trestné činy související s drogami (Eurostat, 2024a; UNODC, 2015). Tyto ukazatele byly následně doplněny o průměrný index HDP na obyvatele, který sloužil jako přibližný ukazatel ekonomické úrovně jednotlivých států (Eurostat, 2024b).

V dalším kroku byla provedena standardizace proměnných pomocí z-skóre, aby všechny proměnné vstupovaly do analýzy se srovnatelnou vahou a výsledky nebyly zkresleny rozdílným měřítkem jednotlivých ukazatelů (James et al., 2021). Optimální počet shluků byl stanoven prostřednictvím metody lokte (elbow method), která porovnává vývoj vnitroshlukové variability při různém počtu clusterů. Výsledky této procedury ukázaly jako nejvhodnější rozdělení dat do tří skupin (Hastie et al., 2009; Pedregosa et al., 2011).

Výstupem shlukové analýzy je tedy rozdělení členských států EU-27 do tří relativně homogenních clusterů, které sdružují země s podobným profilem kriminality a ekonomické úrovně. Shluková analýza v tomto kontextu představuje důležité doplnění klasických konvergenčních metod, protože umožňuje zkoumat nejen vývoj rozdílů mezi státy, ale také jejich strukturální podobnost (James et al., 2021). Zatímco sigma-konvergence sleduje celkovou variabilitu mezi zeměmi (Barro & Sala-i-Martin, 2004), shlukování umožňuje odhalit, zda se v rámci Evropské unie vytvářejí stabilní skupiny států s obdobným bezpečnostním profilem.


Graf 6: Stanovení optimálního počtu shluků pomocí metody lokte (Elbow Method)



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

4.2.1 Charakteristika jednotlivých shluků

Graf 7: Vizualizace shlukové analýzy států EU pomocí PCA projekce



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

Na základě aplikace algoritmu **K-means** byly členské státy Evropské unie rozděleny do tří relativně homogenních skupin. Vizualizace výsledků pomocí metody **PCA** umožňuje přehledně zobrazit vzájemnou podobnost států v redukovaném dvourozměrném prostoru (**James et al., 2021**). Blízkost jednotlivých bodů v grafu indikuje podobný profil kriminality a socioekonomických charakteristik, zatímco větší vzdálenost signalizuje strukturální odlišnost.

Cluster 0 (fialová) – Státy s vysokou mírou hlášené kriminality

Do nultého shluku patří státy západní a jižní Evropy, konkrétně **Švédsko, Belgie, Francie, Nizozemsko, Španělsko, Itálie a Portugalsko**. Tyto země se vyznačují specifickým profilem evidované kriminality, kde se v datech častěji objevují vyšší hodnoty některých forem majetkové a drogové činnosti (**Eurostat, 2024a**).

Tento výsledek však nemusí nutně znamenat vyšší skutečný výskyt trestné činnosti, ale může odrážet vyšší míru hlášení kriminality, kvalitnější statistickou evidenci a efektivnější fungování bezpečnostních institucí v těchto zemích (**UNODC, 2015**). V PCA projekci tvoří tento cluster spojnici mezi ekonomickým jádrem a specifickými severskými modely.

Cluster 1 (tyrkysová) – Ekonomické jádro s vysokou stabilitou

První shluk zahrnuje státy s nejvyšší úrovní HDP na obyvatele a stabilním institucionálním prostředím, konkrétně **Lucembursko, Dánsko, Německo a Rakousko (Eurostat, 2024b)**.

Tyto státy vykazují relativně stabilní a v kontextu EU průměrné hodnoty sledovaných kategorií kriminality v poměru k jejich ekonomickému výkonu. Z hlediska interpretace lze tuto skupinu chápat jako určité hospodářské jádro Evropské unie, kde se vysoká ekonomická výkonnost snoubí s vysokou mírou společenské kontroly a stability (**Barro & Sala-i-Martin, 2004**). V PCA prostoru jsou tyto státy lokalizovány v pravé části, což odpovídá jejich dominantní socioekonomické pozici.

Cluster 2 (žlutá) – Státy střední, východní a jižní periferie

Třetí shluk je nejpočetnější a tvoří jej převážně státy střední a východní Evropy (**Česko, Slovensko, Polsko, Maďarsko, Rumunsko, Bulharsko a pobaltské státy**), které doplňuje **Finsko, Řecko, Kypr, Malta, Chorvatsko a Slovinsko**.

Pro tuto skupinu je charakteristická nižší průměrná ekonomická úroveň měřená HDP na obyvatele a současně odlišná struktura kriminality oproti západním státům. Významnou roli zde mohou hrát historické faktory, odlišný institucionální vývoj po roce 1990 i specifika národních systémů evidence kriminality (**UNODC, 2015**). V PCA projekci jsou tyto státy soustředěny v levé části spektra, což potvrzuje jejich strukturální odlišnost od ekonomicky nejsilnějších členů EU.

4.2.2 Vztah ke konvergenci kriminality

Výsledky shlukové analýzy ukazují, že členské státy Evropské unie netvoří z hlediska kriminality homogenní celek (**James et al., 2021**). Naopak lze identifikovat relativně stabilní skupiny zemí, které do značné míry odpovídají geografickému, historickému a ekonomickému členění Evropy (**Eurostat, 2024a; UNODC, 2015**).

Tento výsledek naznačuje, že proces konvergence kriminality nelze chápat jako plošný a absolutní proces probíhající rovnoměrně napříč celou Evropskou unií. Ačkoli byly v předchozí části analýzy u některých kategorií trestné činnosti identifikovány dílčí známky sigma-konvergence, mezi jednotlivými shluky států nadále přetrvávají významné strukturální rozdíly (**Barro & Sala-i-Martin, 2004**).

Lze tedy předpokládat, že sbližování kriminality probíhá spíše uvnitř jednotlivých skupin států než mezi nimi. Jinými slovy, státy se zjevně nepřibližují k jednomu společnému evropskému modelu kriminality, ale spíše vytvářejí několik odlišných vývojových vzorců (**James et al., 2021**). Tento závěr podporuje hypotézu, že kriminalita je ovlivněna nejen ekonomickou úrovní, ale také širším institucionálním, historickým a sociálním kontextem (**Becker, 1968; UNODC, 2015**).

4.2.3 Stabilita shluků v čase

Je třeba zdůraznit, že shluková analýza byla provedena nad daty agregovanými za celé období 2013–2023, tedy nad průměrnými hodnotami jednotlivých ukazatelů. Z tohoto důvodu není možné přímo sledovat meziroční přesuny států mezi jednotlivými clustery ani přesně vyhodnotit dynamiku jejich změn v jednotlivých letech (**James et al., 2021**).

Identifikované shluky je proto vhodné chápat především jako obraz **dlouhodobých strukturálních podobností** mezi členskými státy, nikoliv jako zachycení krátkodobých výkyvů ve vývoji kriminality. Výhodou tohoto přístupu je omezení vlivu meziroční volatility a dočasných šoků, které by mohly zkreslovat výslednou klasifikaci (**Barro & Sala-i-Martin, 2004; Hastie et al., 2009**).

Současně je však nutné uvést, že přesnější posouzení časové stability clusterů by vyžadovalo dynamický přístup, například opakované provedení shlukové analýzy pro jednotlivé roky nebo kratší časové úseky. Takový postup by umožnil sledovat, zda se státy mezi skupinami v čase přesouvají, nebo zda zůstávají dlouhodobě ve stejných clusterech. Tato úroveň analýzy však přesahuje rámec předložené práce a představuje vhodný směr pro navazující výzkum (**James et al., 2021**).

Celkově lze konstatovat, že identifikované shluky nepředstavují náhodná či krátkodobá seskupení, ale **relativně robustní model dlouhodobého strukturálního rozdělení** členských států Evropské unie na základě jejich profilu kriminality a ekonomické úrovně (**Eurostat, 2024b; UNODC, 2015**).

4.3 Analýza trendů kriminality

V rámci této kapitoly je předchozí analýza vývoje kriminality (viz kapitola 4.1) rozšířena o interpretaci faktorů, které mohou ovlivňovat zjištěné trendy. Cílem není pouze popsat vývoj časových řad, ale zasadit výsledky do širších socioekonomických a institucionálních souvislostí (**Barro & Sala-i-Martin, 2004**).

Z dosažených výsledků vyplývá, že dynamika vývoje jednotlivých typů trestné činnosti se mezi sebou výrazně liší. Toto zjištění podporuje předpoklad, že kriminalitu nelze chápat jako jednotný jev, ale spíše jako soubor dílčích fenoménů s odlišnými příčinami, strukturou a vývojovou dynamikou (**Becker, 1968; Freeman, 1999**).


- **Majetková kriminalita (Vloupání):** V této oblasti byl identifikován výrazný a dlouhodobý konvergenční trend. Tento vývoj lze interpretovat jako důsledek strukturálních změn, mezi něž patří technologický pokrok, rozšíření zabezpečovacích systémů, digitalizace domácností či změny životního stylu obyvatelstva. Významnou roli může hrát také zlepšování preventivních opatření a profesionalizace bezpečnostních složek. Jelikož tyto faktory působí v mnoha evropských státech obdobně, mohou přispívat ke sbližování úrovně majetkové kriminality (**James et al., 2021**).

- **Drogová kriminalita:** Odlišná situace byla zjištěna u této kategorie, kde přetrvává vysoká míra heterogenity mezi státy. Vývoj je pravděpodobně ovlivněn rozdílnými národními politikami, odlišným přístupem k trestní represi, různou intenzitou policejního dohledu a specifiky lokálních trhů s omamnými látkami. Významnou roli mohou hrát rovněž rozdíly v právní kvalifikaci drogových deliktů a způsobech statistické evidence (**Eurostat, 2024a; UNODC, 2015**). Výsledkem je omezená míra konvergence a přetrvávání rozdílů mezi členskými státy.
- **Násilná kriminalita (Úmyslné vraždy):** Specifický charakter vykazuje tato kategorie, kde byla dlouhodobě zaznamenána nízká variabilita mezi státy, což naznačuje relativně stabilní a srovnatelnou úroveň napříč Evropskou unií. Tento stav může souviset s tím, že vraždy patří mezi nejpřesněji evidované trestné činy a současně jsou silně ovlivněny institucionální kapacitou státu, sociální stabilitou a dlouhodobými kulturními faktory (**Messner & Rosenfeld, 2001**). Prostor pro další konvergenci je proto v této oblasti omezený.

Z širšího pohledu lze konstatovat, že rozdílný vývoj jednotlivých kategorií kriminality odráží jejich odlišnou citlivost vůči socioekonomickým faktorům. Některé typy kriminality reagují pružněji na změny ekonomické situace, technologického prostředí nebo demografické struktury, zatímco jiné zůstávají více závislé na národních institucích, legislativě a historickém kontextu (**Becker, 1968; James et al., 2021**). Výsledky tak potvrzují, že analýza kriminality vyžaduje diferencovaný přístup a nelze ji redukovat na jediný univerzální model vývoje.

4.4 Vyhodnocení míry konvergence mezi státy

Graf 8: Test beta-konvergence kriminality mezi státy EU v období 2013–2023



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

Získané analytické výstupy umožňují komplexní vyhodnocení míry konvergence kriminality v referenčním období let 2013–2023. Toto celkové zhodnocení vychází ze čtyř hlavních analytických přístupů: analýzy **sigma-konvergence** (kapitola 4.1), **shlukové analýzy** (kapitola 4.2), **interpretace identifikovaných trendů** (kapitola 4.3) a **testování beta-konvergence** prostřednictvím regresního modelu (**Barro & Sala-i-Martin, 2004; James et al., 2021**).

Na základě výsledků lze konstatovat, že proces konvergence kriminality v evropském prostoru v určité míře probíhá, jeho dynamika a intenzita se však výrazně liší podle typu sledované trestné činnosti. Kriminalitu proto nelze chápat jako jednotný jev s homogenním vývojem, ale jako soubor kategorií s odlišnou dynamikou a rozdílnými determinanty.

- **Majetková kriminalita (Vloupání):** Byla identifikována relativně silná konvergenční tendence. Pokles variability mezi státy naznačuje postupné snižování rozdílů, což pravděpodobně souvisí s technologickým pokrokem a standardizací prevence (**Eurostat, 2024a**).
- **Loupeže:** Situace je méně jednoznačná. Po počátečním sblížování byl trend narušen, což naznačuje citlivost této kategorie na krátkodobé ekonomické a sociální šoky.

- **Násilná kriminalita (Vraždy):** Vykazuje dlouhodobě nízkou a stabilní variabilitu. Prostor pro další konvergenci je v současnosti omezený, neboť státy EU již vykazují srovnatelně nízké úrovně (**UNODC, 2015**).
- **Drogová kriminalita:** Konvergence **nebyla potvrzena**. Přetrvávající rozdíly odrážejí odlišné národní legislativní rámce a institucionální přístupy k drogové politice (**UNODC, 2015**).

Uvedené závěry doplňují výsledky **regresní analýzy beta-konvergence**. Odhadnutý koeficient počáteční úrovně kriminality dosahoval kladné hodnoty, avšak nebyl statisticky významný ($p = 0,371$). Nelze tedy potvrdit existenci systematické beta-konvergence mezi státy Evropské unie ve sledovaném období. Nízká hodnota koeficientu determinace ($R^2 = 0,032$) zároveň naznačuje, že použitý lineární model vysvětluje pouze minimální část variability ve vývoji kriminality (**Seabold & Perktold, 2010**).

Shluková analýza dále ukázala, že státy EU lze rozdělit do relativně stabilních skupin, které odpovídají geografickým a socioekonomickým souvislostem. To naznačuje, že konvergenční procesy probíhají spíše uvnitř jednotlivých skupin států („klubová konvergence“) než rovnoměrně napříč celou Unií (**James et al., 2021**).

Celkově lze uzavřít, že proces konvergence kriminality v Evropské unii je **selektivní a asymetrický**. Vývoj kriminality nelze vysvětlit jednoduchým lineárním vztahem, což potvrzuje její vícerozměrnou povahu ovlivněnou ekonomickými, institucionálními i sociálními faktory (**Becker, 1968; Messner & Rosenfeld, 2001**).

5 Diskuse výsledků

Výsledky provedené analýzy ukazují, že vývoj kriminality v Evropské unii v období 2013–2023 nelze interpretovat jako jednotný a plošný proces konvergence. Naopak se potvrzuje, že dynamika kriminality je výrazně diferencovaná podle jednotlivých kategorií trestné činnosti i podle specifických charakteristik jednotlivých států. Tento závěr je v souladu s teoretickými přístupy, které kriminalitu chápou jako komplexní socioekonomický jev ovlivněný kombinací ekonomických, institucionálních, demografických a kulturních faktorů (**Becker, 1968; Messner & Rosenfeld, 2001**).

5.1 Hlavní zjištění a sektorové rozdíly

Nejvýraznější konvergenční tendence byla identifikována u **majetkové kriminality**, zejména u vloupání do soukromých obydlí. Tento výsledek lze interpretovat jako důsledek sblížování bezpečnostních standardů, širší dostupnosti zabezpečovacích technologií a profesionalizace preventivních strategií napříč EU (**James et al., 2021**).

Naopak **drogová kriminalita** vykazuje dlouhodobě vysokou heterogenitu a slabou míru konvergence. Tento výsledek reflektuje odlišné legislativní přístupy, míru represe a priority trestní politiky v jednotlivých státech. Statistiky v této oblasti tak neodrážejí pouze skutečný výskyt jevu, ale do značné míry i institucionální nastavení daného státu (**UNODC, 2015**).

Specifické postavení zaujímá **násilná kriminalita** (úmyslné vraždy). Nízká variabilita mezi státy naznačuje, že v této oblasti již členské země dosahují relativně podobných hodnot, což je pravděpodobně důsledkem vysoké institucionální kontroly a dlouhodobé stabilizace bezpečnostního prostředí v evropském prostoru (**Eurostat, 2024a**).

5.2 Metodologické a teoretické závěry

Významným zjištěním práce je absence statisticky významné **beta-konvergence**. Skutečnost, že vyšší počáteční úroveň kriminality automaticky neznamenal rychlejší pokles, ukazuje limity jednoduchých lineárních modelů a potvrzuje nutnost zohledňovat komplexní soubor faktorů, jako je kvalita institucí či demografická struktura (**Barro & Sala-i-Martin, 2004**).

Shluková analýza navíc prokázala, že státy EU tvoří relativně stabilní skupiny, které odpovídají geografickému a historickému rozdělení Evropy. To naznačuje, že kriminalita je silně zakořeněna v historickém institucionálním vývoji a nelze ji vysvětlit pouze aktuální ekonomickou úrovní (**James et al., 2021**).

5.3 Omezení a přínos práce

Při interpretaci výsledků je nutné zohlednit limity práce, zejména:

- rozdíly v právních definicích a metodice evidence mezi státy (**Eurostat, 2024a**),
- výběr pouze klíčových kategorií kriminality,
- agregovanou povahu shlukové analýzy, která nezachycuje dynamiku meziročních přesunů.

Navzdory těmto omezením práce ukazuje, že kombinace tradičních konvergenčních metod a **metod strojového učení** představuje vhodný analytický přístup. Zatímco klasické statistické ukazatele sledují vývoj rozdílů (sigma-konvergence), metody jako K-means a PCA poskytují hlubší pohled na strukturální podobnost států.

Celkově lze uzavřít, že kriminalita v Evropské unii prochází spíše **selektivním než plošným procesem konvergence**. Tento poznatek potvrzuje, že bezpečnostní situace v EU zůstává výsledkem kombinace společných evropských trendů a specifických národních podmínek.

Závěr

Cílem této práce bylo analyzovat vývoj kriminality v Evropské unii v období 2013–2023 a zhodnotit, zda mezi jednotlivými státy dochází ke konvergenci. Za tímto účelem byly využity jak tradiční statistické přístupy, konkrétně analýza sigma-konvergence, tak metody strojového učení, zejména shluková analýza.

Výsledky ukazují, že konvergence kriminality v Evropské unii není jednotná a liší se v závislosti na typu trestné činnosti. U majetkové kriminality, zejména vloupání do soukromých obydlí, lze pozorovat relativně jasný trend sblížování mezi státy. Naopak u drogové kriminality přetrvává vysoká míra heterogenity a konvergence se zde neprojevuje. V případě násilné kriminality, reprezentované úmyslnými vraždami, je variabilita mezi státy dlouhodobě nízká, což naznačuje, že k významné konvergenci došlo již v minulosti.

Shluková analýza dále ukázala, že státy Evropské unie se sdružují do relativně stabilních skupin, které odpovídají jejich socioekonomickému a historickému kontextu. Toto rozdělení naznačuje, že i přes ekonomickou a politickou integraci přetrvávají strukturální rozdíly, které ovlivňují vývoj kriminality. Konvergence tak probíhá spíše uvnitř těchto skupin než napříč celou Evropskou unií.

Z metodologického hlediska práce ukazuje, že kombinace tradičních statistických metod a metod strojového učení představuje vhodný přístup pro analýzu komplexních jevů, jakým je kriminalita bezesporu. Využití shlukové analýzy umožnilo identifikovat vzorce, které by při použití pouze klasických metod nemusely být zřejmé.

Je však nutné zohlednit i omezení této práce. Výsledky jsou závislé na kvalitě a srovnatelnosti dat, která mohou být ovlivněna rozdíly v legislativě, míře hlášení trestných činů a způsobu jejich evidence. Dále byla analýza provedena na agregovaných datech, což neumožňuje zachytit dynamiku změn v čase na úrovni jednotlivých států.

Z hlediska dalšího výzkumu by bylo vhodné zaměřit se na dynamickou analýzu shluků v čase, rozšířit spektrum použitých proměnných o další socioekonomické indikátory nebo využít pokročilejší metody strojového učení. Další výzkum by mohl rovněž hlouběji analyzovat vztah mezi konkrétními politikami jednotlivých států a vývojem kriminality.

Celkově lze konstatovat, že kriminalita v Evropské unii představuje komplexní a diferencovaný jev, jehož vývoj nelze redukovat na jednoduchý proces sblížování mezi státy. Přínosem této práce je propojení tradičních statistických metod s metodami strojového učení, které umožnilo zachytit nejen vývoj variability kriminality, ale také strukturální podobnosti mezi členskými státy. Výsledky současně ukazují, že porozumění kriminalitě v evropském prostoru vyžaduje kombinaci kvantitativní analýzy a širšího institucionálního a socioekonomického kontextu.

Použitá literatura:

Al Boni, M., et al. (2016). Crime prediction using ensemble and deep learning. International Conference on Machine Learning and Applications (ICMLA).

Angwin, J., et al. (2016). Machine Bias: There's software used across the country to predict future criminals. And it's biased against blacks. ProPublica.

Berk, R. (2017). Machine Learning Risk Assessments in Criminal Justice Settings. Springer.

Becker, G. S. (1968). Crime and punishment: An economic approach. Journal of Political Economy, 76(2), 169–217.

Ehrlich, I. (1973). Participation in illegitimate activities: A theoretical and empirical investigation. Journal of Political Economy, 81(3), 521–565.

Eurostat. (2024). Crime and criminal justice statistics – Methodological guide. European Commission.

Eurostat. (2024). GDP per capita in PPS. Retrieved from <https://ec.europa.eu/eurostat/>

Eurostat. (2024). Police-recorded offences by offence category. Retrieved from <https://ec.europa.eu/eurostat/>

Fajnzylber, P., Lederman, D., & Loayza, N. (2002). Inequality and violent crime. Journal of Law and Economics, 45(1), 1–39.

GÉRON, Aurélien. Hands-on machine learning with Scikit-Learn, Keras and TensorFlow : concepts, tools, and techniques to build intelligent systems. Beijing: O'Reilly, 2019. ISBN 978-1-4920-3264-9.

HAN, Jiawei; KAMBER, Micheline a PEI, Jian. Data mining : concepts and techniques. Amsterdam: Morgan Kaufmann is and imprint of Elsevier, 2012. ISBN 978-0-12-381479-1.

Freeman, R. B. (1999). The economics of crime. In O. Ashenfelter & D. Card (Eds.), Handbook of Labor Economics (Vol. 3, pp. 3529–3571). Elsevier.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning (2nd ed.). Springer.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning (2nd ed.). Springer.

Messner, S. F., & Rosenfeld, R. (2001). Crime and the American dream (3rd ed.). Wadsworth.

Merton, R. K. (1938). Social structure and anomie. American Sociological Review, 3(5), 672–682.

Mohler, G. O., et al. (2015). Randomized Controlled Field Trials of Predictive Policing. *Journal of the American Statistical Association*, 110(512), 1399–1411.

Tayebi, M. A., & Glässer, U. (2016). *Social Network Analysis in Predictive Policing*. Springer.

Řezanková, H., Húsek, D., & Snášel, V. (2018). *Shluková analýza dat* (2., rozšířené vydání). Professional Publishing.


UNODC. (2015). *International classification of crime for statistical purposes (ICCS)*. United Nations.

Wilkinson, R., & Pickett, K. (2009). *The spirit level: Why greater equality makes societies stronger*. Allen Lane.

Přílohy

Příloha A: Dodatečné grafy a tabulky

Graf 9: Reziiduální graf regresního modelu beta-konvergence kriminality mezi státy EU



Zdroj: Vlastní zpracování na základě dat Eurostat (2024).

Příloha B: Ukázky kódu

B.1 Skript pro přípravu dat

Skript slouží k načtení původních datových souborů Eurostatu, jejich základnímu očištění a vytvoření agregovaného datasetu celkové kriminality.

```
from data_cleaning import clean_crime, prepare_total_crime

crime = clean_crime("../data/crim_off_cat.csv")
crime_total = prepare_total_crime(crime)
```

```
crime_total.to_csv("../data/crime_clean.csv", index=False)
```

B.2 Skript pro čištění a transformaci dat

Skript obsahuje funkce pro úpravu názvů proměnných, převod datových typů, odstranění agregovaných územních celků a filtraci sledovaného období.

```
import pandas as pd

def clean_crime(path):
    df = pd.read_csv(path)

    df = df.rename(columns={
        "geo": "country",
        "TIME_PERIOD": "year",
        "OBS_VALUE": "crime_rate"
    })

    df = df[df["year"] >= 2010]

    excluded = ["EU27_2020", "EU28", "EA19", "EA20"]
    df = df[~df["country"].isin(excluded)]

    return df
```

B.3 Výpočet sigma-konvergence

Sigma-konvergence byla měřena pomocí směrodatné odchylky mezi státy v jednotlivých letech. Pokles variability naznačuje sblížování úrovně kriminality.

```
import pandas as pd

crime = pd.read_csv("../data/crime_clean.csv")

sigma = crime.groupby("year")["crime_rate"].std().reset_index()

print(sigma)
```

B.4 Odhad beta-konvergence

Beta-konvergence byla testována lineární regresí, kde závislou proměnnou představovalo tempo růstu kriminality a vysvětlující proměnnou počáteční úroveň kriminality.

```
import statsmodels.api as sm
import pandas as pd

df = pd.read_csv("../data/beta_dataset.csv")

X = df["initial_crime"]
X = sm.add_constant(X)

y = df["growth_rate"]

model = sm.OLS(y, X).fit()

print(model.summary())
```

B.5 Shluková analýza států EU

Pro identifikaci podobných skupin států byla použita metoda K-means clustering na základě kriminality a ekonomických ukazatelů.

```
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
import pandas as pd

df = pd.read_csv("../data/clustering_data.csv")

X = df[["crime_rate", "gdp_per_capita"]]

X_scaled = StandardScaler().fit_transform(X)

kmeans = KMeans(n_clusters=4, random_state=42)
df["cluster"] = kmeans.fit_predict(X_scaled)

print(df[["country", "cluster"]])
```

B.6 Vizualizace výsledků

Ukázka grafického znázornění vývoje sigma-konvergence v čase.

```
import matplotlib.pyplot as plt
import pandas as pd

sigma = pd.read_csv("../data/sigma_results.csv")

plt.plot(sigma["year"], sigma["crime_rate"])
plt.xlabel("Rok")
plt.ylabel("Směrodatná odchylka")
plt.title("Vývoj sigma-konvergence kriminality v EU")
plt.show()
```